

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа
«Прикладная математика и информатика»

Отчёт об исследовательском проекте на тему:

**Управление перевёрнутым маятником
методами обучения с подкреплением**

Выполнил:
студент группы БПМИ-233
Нефедов Дмитрий Львович

Руководитель проекта:
Бондарев Андрей Олегович
Эксперт Проектно-учебной
лаборатории робототехники
Факультет компьютерных наук НИУ ВШЭ

Москва, 2026

Содержание

Аннотация	3
Введение	4
1 Связанные работы и выбор подходов	6
1.1 Классическое управление как содержательная база сравнения	6
1.2 Четыре подхода к обучению управляющего закона	6
1.3 Защитный фильтр и достоверность сравнения	8
1.4 Позиционирование настоящего исследования	8
2 Модель, защитный фильтр и критерии качества	9
2.1 От установки к расчётной модели	9
2.2 Уравнения и постоянное управление между отсчётами	9
2.3 Наблюдение, запрос и фактически приложенное ускорение	11
2.4 Почему одной проверки положения недостаточно	12
2.5 Как фильтр выбирает команду	13
2.6 Награда и физический критерий успеха	14
2.7 Как измеряется безопасность	15
3 Обучение и правила сравнительного исследования	16
3.1 Обновление моделей и классическая обратная связь	16
3.2 Общие условия и единицы сравнения	17
3.3 Выбор контрольной точки и проверка настройки	18
3.4 Что проверяют данные и что разработано в проекте	19
4 Качество обучения и проверка повторяемости	20
4.1 Какие решения найдены в основной серии	20
4.2 Два разных сравнения фильтра	20
4.3 Ограниченный подбор: победа по правилу и границы объяснения	22
4.4 Подтверждение на новых значениях seed	23
4.5 Маятник сверху: почему это ещё не успех	23
5 Структурированная проверка начальных условий	25
5.1 Что изменяется, а что остаётся фиксированным	25
5.2 Дизайн стартов и отношение к распределению обучения	25
5.3 Сначала исходная задача: новые nominal-состояния	26
5.4 Где проявляются ограничения захвата	26
5.5 Парное вмешательство: безопасность и задача	27
5.6 Насколько часто фильтр меняет запрос	29
Заключение	30
Список использованных источников	31
Приложение А. Полная матрица валидации основной серии	33
Приложение Б. Ключи выбора настройки	34
Приложение В. Состав и воспроизводимость электронных материалов	35
Приложение Г. Видеопримеры сохранённых траекторий	36

Аннотация

Исследуется подъём маятника на тележке из нижней области и его последующее удержание сверху при ограничениях движения. В идеализированной модели с управляемым ускорением тележки сравниваются четыре алгоритма обучения с подкреплением и классический траекторный регулятор. Защитный фильтр проверяет запрос контроллера и при необходимости меняет ускорение, чтобы сохранить тормозной запас тележки. Успех удержания и соблюдение ограничений оцениваются отдельно.

Исследованы 33 обучения по 100 000 переходов: основная серия, ограниченный подбор настроек и их проверка на новых реализациях случайности. Два из изученных методов с фильтром решают все двадцать проверочных сценариев в трёх исходных обучениях. Увеличенный начальный сбор опыта улучшает результат отбора двух неуспешных процедур, но не проходит заранее установленный критерий подтверждения на новых обучениях. Показан случай роста суммарной награды при ухудшении удержания из-за скорости тележки.

Отдельно семь закреплённых контроллеров испытаны на 140 общих стартовых состояниях: 1960 эпизодов, 980 пар с фильтром и без него. Число успехов увеличивается с 441/980 до 796/980; наблюденные превышения желаемой границы с допуском исчезают. Однако 184/980 эпизода с фильтром не выполняют заключительное удержание, хотя достигают горизонта. Выводы относятся к фиксированному диагностическому набору и симуляции. Независимая итоговая оценка и аппаратные испытания не проводились.

Ключевые слова: перевёрнутый маятник; обучение с подкреплением; управление с ограничениями; защитный фильтр; повторяемость обучения; начальные условия; вычислительный эксперимент.

Введение

Перевернутый маятник на тележке представляет собой простую по устройству, но содержательную задачу управления. Привод перемещает тележку, а маятник вращается свободно: отдельного управляющего воздействия на его оси нет. Для подъёма из нижнего положения нужно передать маятнику энергию движением шарнира. Вблизи верхнего неустойчивого равновесия задача меняется: необходимо погасить угловую скорость и компенсировать отклонения. Ограниченная длина направляющей связывает эти этапы. Движение, полезное для подъёма, может не оставить тележке места для торможения.

При известной модели эту задачу можно решать с помощью планирования траектории и обратной связи. Альтернативу даёт обучение с подкреплением: управляющая программа улучшает поведение по опыту взаимодействия со средой. Существование обоих подходов делает маятник удобным объектом сравнительного исследования. Практический вопрос состоит не только в том, способен ли алгоритм однажды поднять маятник, но и в том, повторяется ли результат обучения, сохраняется ли он при других стартах и соблюдаются ли ограничения движения.

Цель работы — исследовать качество подъёма и удержания перевернутого маятника классическим регулятором и выбранными методами обучения с подкреплением в общей модели с ограничениями. Объект исследования — система «тележка — маятник» с управляемым ускорением тележки. Предмет исследования — результативность управления, повторяемость обучения и чувствительность закреплённых контроллеров к начальным условиям и защитному фильтру.

Для достижения цели решаются следующие задачи:

1. согласовать модель, ограничения, наблюдение агента и физический критерий успешного удержания;
2. организовать сравнение DQN, DDPG, SAC, TQC и классического траекторного регулятора при явно заданных условиях;
3. проверить ограниченный подбор настроек и повторяемость выбранного улучшения на новых запусках обучения;
4. оценить одни и те же контроллеры на структурированном наборе начальных состояний с фильтром и без него;
5. разделить причины неуспеха по наблюдаемым признакам и установить границы выводов.

В обучении с подкреплением (reinforcement learning, RL) *агент* получает наблюдение и выбирает действие. Правило такого выбора называется *политикой*. Среда исполняет действие и возвращает новое наблюдение и численную *награду*. Одна попытка управления до заданного времени или досрочной остановки называется *эпизодом*. Агент обучается увеличивать накопленную награду, однако её рост не обязательно означает выполнение физической задачи. Поэтому награда, успех удержания и соблюдение ограничений в работе измеряются отдельно.

Случайная инициализация нейросетей и сбор опыта влияют на найденную политику. Начальное значение генераторов случайных чисел (*seed*) задаёт конкретную реализацию случайности. Разные *seed* обучения не означают разные границы распределения начальных

состояний. Сохранённые параметры модели образуют *контрольную точку* (checkpoint). В работе различаются лучшая по правилу отбора точка и последние веса одного обучения; это две версии одной модели, а не два независимых запуска.

Для выбора модели используется *валидация*: оценка на фиксированных состояниях, результаты которой участвуют в отборе. Такие состояния нельзя затем считать независимым итоговым тестом. Аналогично, проверка выбранной настройки на новых seed характеризует повторяемость обучения, но не заменяет испытание на новых физических стартах. Под *робастностью* далее понимается эмпирическое сохранение качества при изменении начальных условий. Устойчивость к шумам, задержкам и ошибкам параметров в этот эксперимент не входит.

Защитный фильтр проверяет запрос контроллера и при необходимости меняет ускорение, сохраняя тормозной запас тележки. При включённом фильтре оценивается система «контроллер вместе с фильтром»: её успех нельзя целиком приписывать нейросети. В то же время защита положения не обеспечивает подъём и удержание сама по себе. Именно поэтому сравнение проводится как между процедурами обучения, так и между двумя режимами исполнения одних весов.

Эксперименты включают основную серию из 15 обучений, этап подбора настроек из 12 обучений и проверку выбранных настроек из шести обучений. Каждый запуск содержит 100 000 переходов, суммарно — 3,3 млн. Дополнительно семь фиксированных контроллеров оценены на 140 общих стартовых состояниях: 1960 эпизодов, образующих 980 пар с фильтром и без него. Повторное использование стартов обеспечивает сопоставимость, но не превращает эти пары в независимую выборку из всего пространства состояний.

Основные результаты. SAC и TQC с фильтром решают все двадцать валидационных сценариев в каждом из трёх исходных обучений. Подбор увеличенного начального сбора опыта для DDPG с фильтром и SAC без него улучшает результат отбора, но не проходит последующую проверку повторяемости. В структурированной матрице включение фильтра увеличивает число успехов с 441/980 до 796/980 и устраняет наблюдаемые превышения желаемой границы с учётом допуска. При этом 184/980 эпизода с фильтром завершают горизонт без успешного заключительного удержания. Эти результаты показывают различие между допустимым движением тележки и выполнением полной задачи.

Вклад проекта состоит в построении согласованной экспериментальной цепочки на основе лабораторного симулятора и в сравнительном анализе полученных результатов. Подготовлены интерфейс среды, обработка событий ограничений, защитный слой, протокол выбора моделей и средства анализа. Разделены влияние фильтра, случайности обучения и начального состояния; сохранены отрицательные результаты. Лабораторная динамика, основа классического управления и библиотечные алгоритмы обучения имеют самостоятельное происхождение. Разработка нового универсального алгоритма управления не заявляется.

Работа ограничена симуляцией с идеально задаваемым ускорением. Обученные политики на оборудовании не испытывались, независимая итоговая оценка после всех решений разработки не проводилась. Эти ограничения учитываются при обсуждении каждого результата.

1 Связанные работы и выбор подходов

Рассматриваемая задача объединяет три вопроса: построение управляющего закона, соблюдение ограничений и корректное сравнение результатов. Литература по каждому из них даёт разные основания для экспериментального протокола. Ниже обсуждается не общий рейтинг алгоритмов, а то, какие свойства подходов существенны для подъёма маятника на короткой направляющей.

1.1 Классическое управление как содержательная база сравнения

Линейно-квадратичный регулятор (Linear Quadratic Regulator, LQR) выбирает линейную обратную связь по отклонению от равновесия. Коэффициенты определяются из квадратичного штрафа за отклонение состояния и усилие управления. Для нелинейного маятника такой регулятор применяется к линеаризации около верхнего положения: он решает задачу локальной стабилизации, но сам по себе не задаёт подъём снизу. Траекторная оптимизация дополняет его: сначала строится номинальное движение, затем регулятор компенсирует отклонения от него. Эти методы изложены Р. Тедрейком [10, 11].

Разделение подъёма и стабилизации связано с нелинейностью задачи. Линеаризация описывает малые отклонения от выбранного движения; её точность не распространяется автоматически на нижнее положение маятника. Поэтому траекторный регулятор использует изменяющееся во времени опорное движение, а стационарный LQR включается около верхнего равновесия. Сопоставлять такой подход с обучаемой политикой следует по полной задаче подъёма и удержания, сохраняя сведения о способе построения опорной траектории.

В проекте классическая процедура включает заранее сохранённую траекторию подъёма, слежение с обратной связью и переход к LQR. Она нужна не только как техническая проверка симулятора. Если известная модель уже допускает эффективное классическое решение, успех обучаемого метода следует сопоставлять с ним, а не только с бездействием. Вместе с тем одна фиксированная траектория не обязана подходить всем расширенным стартам; это ограничение учитывается при интерпретации.

Исходный лабораторный проект `robotics-laboratory/cart-pole` предоставляет модель и основу классического управления [8]. Его вход — ускорение тележки, а не сила двигателя. Поэтому совпадение названия `CartPole` с другими средами не делает результаты сопоставимыми: необходимо проверить уравнения, начальную область, длину направляющей и критерий успеха. Настоящая работа сохраняет лабораторную динамику и строит вокруг неё общий экспериментальный протокол.

1.2 Четыре подхода к обучению управляющего закона

Все рассматриваемые методы используют нейросетевую оценку ценности действия: ожидаемой будущей суммы наград при его выборе и последующем поведении. Такая оценка позволяет учитывать отложенный результат. Например, кратковременное движение тележки от центра может быть полезным, если впоследствии позволяет поднять маятник. Ценность не равна немедленной награде и сама является приближением, которое меняется при обучении.

DQN (Deep Q-Network) обучает оценки для дискретных действий. Повторное использование переходов из буфера опыта и медленно меняющаяся целевая сеть снижают зависимость обучения от последовательности соседних наблюдений [6]. В нашей задаче DQN выбирает один из девяти запросов ускорения. Это простой дискретный подход, но набор доступных запросов уже, чем у непрерывных методов. Общая физическая среда не означает одинакового класса возможных управляющих законов.

DDPG (Deep Deterministic Policy Gradient) предназначен для непрерывных действий. Сеть управления, *актор* (actor), выдаёт действие, а сеть оценки, *критик* (critic), предсказывает его ценность. Актор меняется в направлении роста предсказанной ценности; исследование обеспечивается добавленным шумом [5]. DDPG выбран как базовый непрерывный метод. Зависимость от качества критика делает полезной проверку разных seed, но сама архитектура ещё не объясняет неуспех конкретного обучения.

SAC (Soft Actor-Critic) сочетает рост ожидаемого возврата с энтропией, то есть мерой разнообразия распределения действий. Стохастическая политика поддерживает исследование, а две оценки критиков используются для более осторожной цели обновления [1]. Вариант с автоматической настройкой веса энтропии описан в развитии метода [2]. Для маятника SAC интересен как способ находить последовательность подъёма без заранее заданной траектории. Энтропия, однако, не является ограничением положения тележки; её нельзя считать заменой защиты.

TQC (Truncated Quantile Critics) сохраняет энтропийного актора, но критики предсказывают квантили распределения возврата вместо одного среднего. При построении обучающей цели часть наиболее высоких прогнозов отбрасывается [4]. Это механизм контроля переоценивания, а не встроенная проверка физических границ. Сопоставление SAC и TQC показывает результат двух полных процедур. Без отдельного эксперимента с выключенным усечением оно не устанавливает, что возможное преимущество вызвано именно квантилями.

Выбор четырёх методов позволяет сопоставить несколько способов построения политики. DQN представляет дискретный выбор запросов, DDPG — детерминированное непрерывное управление, SAC — стохастическое управление с энтропийным критерием, TQC — его развитие с распределительной оценкой возврата. Это не исчерпывающий обзор всех современных алгоритмов. Такой набор выбран для содержательного сравнения при доступном бюджете; добавление новых методов без сопоставимого подбора параметров само по себе не сделало бы выводы сильнее.

Различия алгоритмов не следует путать с доказанными причинами экспериментальных исходов. Например, успешность TQC не доказывает пользу усечения квантилей без отдельного сравнения с отключённым усечением. Аналогично, неудача DQN не устанавливает, что девяти действий недостаточно: одновременно влияют обучение оценки ценности, исследование среды и бюджет переходов. Поэтому результаты интерпретируются на уровне полных процедур.

Использованы реализации Stable-Baselines3 и SB3-Contrib [7, 9]. В проекте разработаны среда, общий путь команд, протокол и анализ; библиотечные алгоритмы не переписаны и не выдаются за авторские. Общие небольшие сети и одинаковый бюджет взаимодействий делают

сравнение обозримым, но не гарантируют индивидуально оптимальных настроек каждого метода. Из полученного порядка результатов нельзя выводить общий рейтинг алгоритмов на всех задачах управления.

1.3 Защитный фильтр и достоверность сравнения

Предиктивные защитные фильтры отделяют предложение контроллера от проверки допустимости. В работе Wabersich и Zeilinger фильтр использует прогноз ограниченной нелинейной системы и при необходимости корректирует вход [12]. В нашем случае реализована более узкая процедура: аналитический прогноз координаты и скорости тележки при постоянном ускорении. Она не является воспроизведением общего нелинейного алгоритма из этой статьи и не наследует автоматически его гарантии для неопределённой динамики.

Safe-control-gym объединяет оценку качества и безопасности классических и обучаемых регуляторов, в том числе при возмущениях [13]. Для настоящей работы важен принцип раздельных метрик: агент может достичь цели с нарушением ограничения или сохранить ограничение, не достигнув цели. В нашем протоколе шумы, задержки и ошибки параметров не испытывались. Поэтому численные результаты здесь не сопоставляются напрямую с этим набором задач; он задаёт методологический ориентир.

Henderson и соавторы показывают, насколько выводы о глубоком обучении с подкреплением зависят от случайности и деталей процедуры [3]. Это мотивирует сохранение каждого запуска, отдельную оценку последних весов и проверку выбранной настройки на новых seed. Три значения seed не дают точной оценки распределения качества будущих обучений, но позволяют увидеть крупную неоднородность, скрытую единственным успешным примером.

1.4 Позиционирование настоящего исследования

Из рассмотренных работ следуют три требования к сравнению. Во-первых, одинаковое название задачи не гарантирует одинаковой динамики и ограничений; модель и критерии необходимо определить явно. Во-вторых, ограничение движения требует отдельного механизма и отдельных показателей: высокая награда не является сертификатом безопасности. В-третьих, результат единственного обучения недостаточен для оценки повторяемости процедуры.

Настоящий проект реализует эти требования в лабораторной модели с ускорительным входом. Его результат — не универсальное преимущество RL над классическим управлением, а воспроизводимое сопоставление конкретных процедур и диагностика их ограничений. Общая модель делает физические результаты сравнимыми, а разделение отбора, новых запусков и новых стартов позволяет уточнить, на какие данные опирается каждый вывод. В следующей главе эти принципы переводятся в уравнения и измеряемые критерии.

2 Модель, защитный фильтр и критерии качества

2.1 От установки к расчётной модели

Тележка перемещает шарнир маятника вдоль горизонтальной направляющей. Движение шарнира меняет угол маятника, хотя отдельного привода на его оси в расчётной модели нет. Рисунок 1 показывает лабораторную установку из предоставленной видеозаписи, а Рисунок 2 помогает различить основные узлы. Эти изображения объясняют устройство; они не свидетельствуют об испытании наших обученных политик на стенде.



Рисунок 1 – Лабораторная установка. Кадр из предоставленного автором видео; не запись экспериментов настоящей серии.




Рисунок 2 – Основные узлы установки. Схематическое изображение; не фотография и не точный технический чертёж.

Состояние обозначим $s = (x, v, \theta, \omega)$. Здесь x — горизонтальная координата шарнира в метрах, $v = \dot{x}$ — скорость тележки в м/с, θ — угол в радианах от вертикали вниз, $\omega = \dot{\theta}$ — угловая скорость в рад/с. Положительное направление x — вправо. При небольшом положительном θ конец маятника смещён вправо от нижней вертикали. Нижнему равновесию соответствует $\theta = 0$, верхнему — $\theta = \pi$ с точностью до полного оборота 2π .

Рисунок 3 закрепляет геометрические соглашения. В классическом регуляторе используется порядок $q = (x, \theta, v, \omega)$; это перестановка компонент того же физического состояния.

2.2 Уравнения и постоянное управление между отсчётами

Контроллер задаёт ускорение тележки u в м/с². Приняты уравнения

$$\dot{x} = v, \quad \dot{v} = u, \quad \dot{\theta} = \omega, \quad \dot{\omega} = -\frac{u \cos \theta + g \sin \theta}{l}. \quad (1)$$

Положение конца идеализированного маятника относительно шарнира равно $(l \sin \theta, -l \cos \theta)$. Проекция ускорения на касательную даёт $l\ddot{\theta} + u \cos \theta = -g \sin \theta$, что согласуется с последним уравнением (1). Около верха при $\varphi = \theta - \pi$ получаем $\ddot{\varphi} \approx (g/l)\varphi + u/l$: без подходящей обратной связи малое отклонение нарастает.

Это модель с идеально заданным ускорением, а не полная система с управлением силой двигателя. Реакция маятника не изменяет предписанное ускорение тележки; масса не входит в




Рисунок 3 – Соглашения расчётной модели: угол от нижней вертикали, вход $u = \ddot{x}$, длина $l = 0,18$ м. Пунктир — желаемые границы положения шарнира $\pm 0,24$ м. Масштаб условный; размеры тележки и концы направляющей ограничений модели не задают.

уравнения. Трение, инерция и насыщение привода по силе, люфт, шум измерений и задержки не описаны. Следовательно, найденное управление нельзя переносить на установку только пересчётом единиц: нужно отдельно проверить исполнение ускорения и адекватность динамики.

Параметры приведены в Таблице 1. Длина и рабочие пределы восходят к лабораторной конфигурации; в экспериментальном контракте они заданы явно вместе с g и аварийными пределами. Это настройки симуляции, не результаты идентификации оборудования. Копии контракта и конфигураций перечислены в Приложении В.

Таблица 1 – Параметры модели и уровни ограничений

Величина	Значение	Смысл
g, l	9,8 м/с ² ; 0,18 м	Ускорение тяжести и длина маятника
$\Delta t, T$	0,01 с; 10 с	Интервал управления и горизонт эпизода
A	4 м/с ²	Максимум приложенного $ u $ при обоих режимах
X, V	0,25 м; 2 м/с	Границы прекращения эпизода по x, v
L_{desired}	0,24 м	Желаемая граница защиты по положению
Аварийный $ x $	0,27 м	Дополнительный предел исходного симулятора
Аварийные $ v , u $	2,5 м/с; 5 м/с ²	Внутренняя аварийная политика
Интегратор	Адаптивный RK3	Точность 10^{-6} , шаг не более 0,01 с; фиксированный шаг выключен

Между моментами управления команда постоянна. За интервал длины h движение тележки известно аналитически:

$$x(\tau) = x_0 + v_0\tau + \frac{1}{2}u\tau^2, \quad v(\tau) = v_0 + u\tau, \quad 0 \leq \tau \leq h. \quad (2)$$

Формулы (2) позволяют проверить весь интервал, включая внутренний экстремум x , а не только конечный отсчёт. Общий исполнитель команд находит первое предстоящее нарушение $|x| \leq X$ или $|v| \leq V$ и останавливает переход на границе. Касание с возвращением внутрь не считается выходом. Состояние маятника до фактического момента остановки вычисляет исходный Drake; отдельный упрощённый интегратор его не заменяет.

Событие достижения границы положения означает остановку перед выходом за $\pm 0,25$ м. Оно не обязательно означает численное превышение этого предела и отличается от превышения желаемых $\pm 0,24$ м. Переход может быть укороченным или нулевым при движении наружу из граничного состояния. После терминального события следующее исполнение запрещено до нового сброса среды. Ошибки симулятора и исключения интегратора не превращаются в успешное завершение.

2.3 Наблюдение, запрос и фактически приложенное ускорение

Агенту передаётся не внутренний вектор Drake, а наблюдение

$$o(s) = \left(x/0,25, v/2, \sin \theta, \cos \theta, \omega/\sqrt{g/l} \right). \quad (3)$$

В (3) величины безразмерны. Синус и косинус представляют угол без разрыва на границе полного оборота; две записи угла, отличающиеся на 2π , описывают одну конфигурацию. Наблюдение округляется до float32, но физический журнал хранит полный угол и исходные компоненты состояния. Классический регулятор получает состояние непосредственно.

SAC, TQC и DDPG формируют нормированный запрос $a \in [-1, 1]$, которому соответствует $u_{\text{req}} = 4a$. Для DDPG при обучении сначала добавляется исследовательский шум, затем запрос ограничивается указанным диапазоном. DQN выбирает индекс одного из девяти ускорений $\{-4, -3, \dots, 3, 4\}$ м/с². После фильтра его исполняемая команда может лежать между узлами сетки. Классическая обратная связь выдаёт физический запрос u_{req} , который до общего исполнительного слоя может превышать ± 4 .

В режиме *off* исполнитель ограничивает амплитуду: $u_{\text{cmd}} = \min(A, \max(-A, u_{\text{req}}))$. В режиме *on* фильтр получает **исходный физический запрос**, а ограничение амплитуды входит в вычисляемое им множество допустимых команд. Величина вмешательства измеряется относительно исходного запроса, поэтому включает и коррекцию амплитуды, если запрос выходит за пределы допустимых ускорений. Рисунок 4 показывает общий путь.

Фильтр читает исходные x, v полной точности, а не восстанавливает их из наблюдения. Выбранное ускорение передаётся в Drake непосредственно, без повторной нормализации и преобразования в float32. *Приложенное ускорение* — команда последнего реально выполненного перехода. Если время не продвинулось, приложенной команды нет: приложенное ускорение считается отсутствующим, а не равным нулю. Эта оговорка существенна для отказа до начала движения.

Буфер опыта (replay buffer) хранит наблюдение, **запрошенное** действие, награду, следующее наблюдение и признак окончания. Записи затем многократно используются для обучения. При *on* агент учится выбирать запросы к среде, которая включает защитное

Replay: запрос а; журнал: запрос, команда, фактически выполненное и




Рисунок 4 – Путь команды и обратной связи. On — фильтр с ограничением амплитуды; off — обычный ограничитель. Оба режима сохраняют события рабочих границ. В буфер опыта поступает запрос агента, а в журнал — запрос, выбранная команда и фактическое исполнение.

преобразование $F(s, u_{\text{req}})$. Замена запроса исполненным ускорением в буфере изменила бы эту задачу. Энтропия SAC и TQC тоже относится к запросам: несколько разных запросов могут после защиты дать одну команду.

2.4 Почему одной проверки положения недостаточно

Если тележка ещё внутри направляющей, но быстро движется к краю, текущая допустимая координата не гарантирует возможности остановиться. При максимальном торможении A тормозной путь равен $v^2/(2A)$. Например, из $x = 0,23$ м при $v = 0,5$ м/с для остановки вправо нужно $0,03125$ м. Точка остановки $0,26125$ м лежит за желаемой границей. Такой старт нельзя исправить простым ограничением текущего ускорения.

В фильтре используются внутренние пределы $L = 0,24 - 10^{-6}$ м и $W = 2 - 10^{-6}$ м/с. Обозначим $[z]_+ = \max(z, 0)$. Допустимая область координаты и скорости:

$$K = \left\{ (x, v) : |x| \leq L, |v| \leq W, x + \frac{[v]_+^2}{2A} \leq L, -x + \frac{[-v]_+^2}{2A} \leq L \right\}. \quad (4)$$

Два последних условия (4) требуют места для торможения в сторону движения. Проверка K не учитывает угол маятника: она предназначена для тележки. Из принадлежности K не следует возможность успешного подъёма маятника за 10 с.

При обучении с фильтром сброс допускает только K , без повторного случайного подбора и без изменения координат. При off проверяется рабочий прямоугольник $|x| \leq 0,25$, $|v| \leq 2$. Весь использованный малый обучающий диапазон входит в K , поэтому состав обучающих стартов не меняется из-за этой проверки. Для произвольных стартов различие уже существенно. Исполнитель классики проверяет ограничения сброса и затем допустимость команды; особенности его метаданных обсуждаются в Главе 5.

2.5 Как фильтр выбирает команду

Пусть до следующего момента управления осталось $h \leq 0,01$ с. Фильтр рассматривает постоянные ускорения и строит множество

$$\mathcal{U}_h(x_0, v_0) = \{u \in [-A, A] : |x(\tau)| \leq L, |v(\tau)| \leq W \quad \forall \tau \in [0, h], \\ (x(h), v(h)) \in K\}. \quad (5)$$

В (5) первая проверка защищает ближайший интервал, а последняя сохраняет возможность торможения после него. Для координаты проверяются начало, конец и вершина параболы $\tau_* = -v_0/u$, если $u \neq 0$ и $0 < \tau_* < h$. Скорость линейна, поэтому её абсолютный максимум достигается на одном из концов.

В реализации допустимые ускорения образуют интервал. Его границы получаются из аналитических ограничений скорости, положения и конечного тормозного пути; левое ограничение вычисляется симметричным отражением x, v, u . Это одномерная аналитическая процедура, без запуска общего оптимизационного решателя. В идеальной арифметике выбирается ближайший к запросу элемент интервала:

$$u_{\text{proj}} = \min(u_{\text{max}}, \max(u_{\text{min}}, u_{\text{req}})), \quad [u_{\text{min}}, u_{\text{max}}] = \mathcal{U}_h(x_0, v_0). \quad (6)$$

Формула (6) сохраняет уже допустимую команду. Если запрос заставит тележку потерять тормозной запас, он сдвигается к ближайшей допустимой границе. Поэтому фильтр не задаёт самостоятельную траекторию подъёма и не оптимизирует награду: он минимально корректирует текущий запрос в рамках проверяемых ограничений.

Численная реализация уточняет эту идеальную проекцию. Исходные двоичные числа проверяются точной рациональной арифметикой; корни для границ вычисляются с повышенной десятичной точностью. Концы округляются внутрь и повторно проверяются. При необходимой коррекции на геометрической или скоростной границе допускается дополнительный сдвиг внутрь не более 10^{-8} м/с², ограниченный шириной интервала. Поэтому исполняемая команда может немного отличаться от точной математической проекции. Координаты состояния при этом не округляются и не подрезаются ради допуска.

Вмешательство зарегистрировано, если принятая фильтром команда отличается от исходного запроса. Его величина равна $|u_{\text{filtered}} - u_{\text{req}}|$. Для классики сюда входит и ограничение большой амплитуды. *Отказ* — иной исход: состояние недопустимо либо не удалось подтвердить представимую численную команду. Тогда эпизод завершается до движения из-за отказа фильтра, с нулевой длительностью и отсутствующей приложенной командой. Отказ не маскируется нулевым управлением.

В точной модели условие $Ah \leq W$, $Ah^2 \leq 2L$ обеспечивает существование допустимого постоянного ускорения из любого $(x, v) \in K$. Смысл конструктивного аргумента следующий. При достаточно большой скорости подходит полное торможение; при малой — остановка к концу шага, если до края хватает пути, либо разворот с полным торможением. Случай движения влево

симметричен. Конец остаётся в K , что позволяет повторять рассуждение по шагам. Предпосылки и ссылка на реализацию приведены в электронном приложении «Фильтр тележки».

Обоснование требует точной модели, исходных состояний без ошибок, неизменных пределов и исполнения команды на заданное время без задержек. Оно не доказывает удержание маятника, общую безопасность численного Drake или работоспособность реального привода. Внутренний запас 10^{-6} м — параметр протокола, а не измеренная граница ошибки оборудования. Эксперимент далее проверяет конечный набор исполнений, отдельно от такого математического аргумента.

2.6 Награда и физический критерий успеха

Награда R1 плавно поощряет верхнее положение и малые отклонения. Обозначим $q(z) = (1 + z^2)^{-1}$ и $H(\theta) = (1 - \cos \theta)/2$. На конце перехода фактической длительности h_k вычисляется

$$r_k = \frac{h_k}{\Delta t} H(\theta_{k+1}) q\left(\frac{x_{k+1}}{0,25}\right) q\left(\frac{v_{k+1}}{2}\right) q\left(\frac{\omega_{k+1}}{2}\right) q\left(\frac{u_{\text{applied},k}}{40}\right) - 5d_k. \quad (7)$$

В (7) $d_k = 1$ при терминальном завершении по рабочему ограничению или отказу фильтра; масштабы имеют единицы соответствующих физических величин. Угловая скорость в награде нормируется на 2 рад/с, а в наблюдении — на $\sqrt{g/l}$; это разные роли. Масштаб 40 м/с² эквивалентен коэффициенту 0,1 перед нормированным ускорением. Положительная часть на полном шаге лежит в $[0, 1]$, постоянного бонуса за выживание нет. При нулевом переходе она равна нулю, штраф остаётся -5 .

Отчётный *возврат* (return) — недисконтированная сумма $G = \sum_k r_k$. При обучении будущие награды умножаются на степени коэффициента $\gamma = \exp(-0,01/5) \approx 0,998002$. Достижение горизонта — временное усечение: при обновлении ценности учитывается возможность продолжения из конечного наблюдения. Физический отказ прекращает такое продолжение. Это различие сохраняется в буфере опыта и не менялось ради результатов.

Критерий задачи задаётся отдельно. Пусть $e_\theta = \text{atan2}(\sin(\theta - \pi), \cos(\theta - \pi))$ — периодическая ошибка относительно верха. Область удержания:

$$|e_\theta| \leq 10^\circ, \quad |\omega| \leq 0,5 \text{ рад/с}, \quad |x| \leq 0,20 \text{ м}, \quad |v| \leq 0,20 \text{ м/с}. \quad (8)$$

Успех требует полного горизонта 10 с без терминального отказа и заключительного непрерывного по записанным отсчётам интервала $H_f \geq 2$ с в области (8). Самый длинный такой интервал за весь эпизод обозначим H_ℓ . Раздельные посещения области не суммируются: если тележка вышла из скоростного порога, интервал удержания прерывается. Допуск времени равен 10^{-12} с. Проверка только угла означает посещение верха и существенно слабее успеха. Соблюдение угловых условий между отсчётами не доказано.

Награда и успех могут расходиться без ошибки расчёта. Небольшое превышение жёсткого порога скорости разрушает двухсекундное удержание, но почти не меняет плавный множитель награды. Кроме того, возврат суммируется по всей траектории, а успех зависит от её конца.

Поэтому выбор модели ниже опирается на удержание, а возврат используется как дополнительная диагностическая величина.

2.7 Как измеряется безопасность

Для положения используется интервальный максимум $M_x = \max_t |x(t)|$, включая аналитический экстремум между командами. Строгое превышение означает $M_x > 0,24$ м; превышение с учётом численного допуска (*resolved*) — $M_x > 0,24 + 10^{-12}$ м. Этот допуск относится к анализу, не переносит границу события с 0,25 м и не заменяет внутренний запас фильтра 10^{-6} м.

Для расчёта превышений дополнительно учитываются аналитическое конечное положение тележки и численно устойчивое суммирование. Версия расчёта зафиксирована в электронных материалах. Успех без превышения с допуском — пересечение двух критериев. Он не переопределяет исходный успех удержания и не означает отсутствия всех возможных опасностей.

Доля вмешательств оп — число изменённых принятых решений, делённое на число всех принятых решений. При агрегировании суммируются оба счётчика; среднее процентов эпизодов не применяется. При выключенном фильтре доля вмешательств не определена: отсутствие защитного слоя отличается от его работы без коррекций. Отказы считаются отдельно. Такой набор метрик различает успех с нарушением желаемой границы, остановку у края и допустимое движение без удержания — именно эти различия существенны для последующих результатов.

Таким образом, постановка разделяет три объекта: запрос контроллера, исполняемую команду и физический исход эпизода. Фильтр ограничивает движение тележки на основе модели; награда направляет обучение; критерий удержания определяет успех. Их отдельное описание необходимо, чтобы далее сравнивать одинаковые величины и не подменять решение задачи соблюдением одного ограничения.

3 Обучение и правила сравнительного исследования

3.1 Обновление моделей и классическая обратная связь

Обучение чередует сбор переходов среды и обновление нейросетей по буферу опыта. Одни и те же переходы могут использоваться повторно, поэтому методы называют *off-policy*: текущая политика учится по опыту, собранному в том числе прежними версиями. Критик приближает дисконтированную ценность запроса, а актор, если он есть, формирует запрос по наблюдению. Целевая сеть — медленно меняющаяся копия, используемая для вычисления ориентиров обучения.

Ниже o, a, r, o' обозначают наблюдение, запрос, награду и следующее наблюдение; $d = 1$ означает терминальное событие, без продолжения оценки будущего возврата. Временное усечение по горизонту этим событием не считается. Q_ψ — критик с параметрами ψ , μ_η или π_η — актор с параметрами η ; черта над параметрами обозначает целевую сеть. Величина y — целевое значение для обновления критика, а не непосредственно измеренный будущий возврат.

Обновление критика опирается на разложение будущего результата: награда ближайшего перехода плюс оценка того, что можно получить после него. Поскольку истинный будущий возврат неизвестен, для второго слагаемого используется целевая сеть. Критик уменьшает расхождение собственного прогноза с этой составной целью. Актор в непрерывных методах затем выбирает действия с высокой оценкой критика. Таким образом, ошибка оценки может влиять и на обучение политики; высокий прогноз критика ещё не является измеренным качеством управления.

Для DQN цель имеет вид $y = r + \gamma(1 - d) \max_{a'} Q_{\bar{\psi}}(o', a')$. Сеть приближает эту цель по сохранённым переходам; при оценке выбирается индекс максимальной ценности. В обучении применяется ϵ -жадное исследование: вероятность случайного запроса линейно уменьшается от 1 до 0,05 за первые 20% бюджета. Целевая сеть обновляется каждые 1000 переходов. Рассматривается обычный DQN из используемой библиотеки; дополнительные алгоритмы под тем же именем не вводятся.

DDPG использует цель $y = r + \gamma(1 - d)Q_{\bar{\psi}}(o', \mu_\eta(o'))$, где μ_η — детерминированный актор. Его обновление направлено на увеличение $Q_\psi(o, \mu_\eta(o))$. В конфигурации один критик; исследование обеспечивается независимым гауссовым шумом со стандартным отклонением $\sigma = 0,1$ в нормированных запросах. Шум отключён при оценке. Исследовательский шум создаёт разнообразие опыта при обучении, но не меняет детерминированное правило внешней оценки.

SAC оптимизирует не только возврат, но и энтропию запросов. Для выбранного следующего запроса $a' \sim \pi_\eta(\cdot|o')$ цель двух критиков записывается как

$$y = r + \gamma(1 - d) \left[\min_{j=1,2} Q_{\bar{\psi}_j}(o', a') - \alpha \log \pi_\eta(a'|o') \right]. \quad (9)$$

Актор минимизирует среднее $\alpha \log \pi_\eta(a|o) - \min_j Q_{\psi_j}(o, a)$. Коэффициент α в (9) настраивается автоматически с начальным значением 0,1. Внешняя оценка использует детерминированный

режим библиотечной политики, а не новый случайный выбор действий. Это важно: случайность обучения и случайность исполнения не смешиваются.

TQC сохраняет энтропийного актора, но вместо одного числа каждый критик предсказывает 25 квантилей распределения возврата. В исследованной конфигурации два критика, параметр удаления верхних квантилей равен двум на сеть: из объединённых 50 прогнозов для цели остаются 46 нижних. Обучение критиков использует квантильную регрессию. Этот механизм предназначен для контроля переоценивания, однако эксперимент здесь проверяет итоговую процедуру TQC целиком, без отдельного выключения усечения.

Квантили описывают различные уровни возможного возврата, а не разные физические траектории, рассчитанные вперёд. Усечение верхней части прогнозов делает цель осторожнее по отношению к завышенным оценкам. При этом ни критик, ни актор TQC не проверяют тормозной путь тележки; такую проверку по-прежнему выполняет общий фильтр.

Классический контроллер сначала следует сохранённому решению прямой коллокации — поиску состояний и входов на временной сетке с ограничениями динамики: номинальным состоянию $q_0(t)$ и ускорению $u_0(t)$. TVLQR (Time-Varying Linear Quadratic Regulator) — линейно-квадратичный регулятор с зависящими от времени коэффициентами — задаёт запрос

$$u_{\text{req}}(t) = u_0(t) - K(t)(q - q_0(t)) - k_0(t), \quad q = (x, \theta, v, \omega). \quad (10)$$

Аффинный член k_0 в (10) учитывает дефект восстановленной номинальной траектории. После конца плана выполняется однократный переход к стабилизирующему LQR: $u = -K_b(x, e_\theta, v, \omega)^T$, с матрицей штрафа за состояние $Q = \text{diag}(10, 1, 10, 1)$ и штрафом за управление $R = 0,5$. Ошибка угла периодическая только в режиме балансировки; слежение сохраняет запланированный полный оборот. Повторного планирования и нового подъёма после неудачного захвата нет. Таким образом, это конкретный классический baseline, а не оптимальный регулятор для каждого нового старта.

3.2 Общие условия и единицы сравнения

Исходное распределение сброса среды (*reset*) — произведение независимых равномерных распределений:

$$\begin{aligned} x_0 &\sim U[-0,02, 0,02] \text{ м}, & v_0 &\sim U[-0,02, 0,02] \text{ м/с}, \\ \theta_0 &\sim U[-0,05, 0,05] \text{ рад}, & \omega_0 &\sim U[-0,05, 0,05] \text{ рад/с}. \end{aligned} \quad (11)$$

Значение *seed* обучения задаёт поток случайности, но не границы (11). Для on и off весь этот малый прямоугольник допустим при сбросе. Посещение других состояний во время движения не означает, что они использовались как исходные состояния обучения.

Каждое обучение в анализируемых сериях содержит 100 000 переходов, одну среду, буфер на 100 000 записей и пакеты по 64 перехода (размер пакета, *batch size*). Сети имеют два скрытых слоя по 64 нейрона с ReLU, функцией $z \mapsto \max(0, z)$; параметры обновляет оптимизатор Adam по оценке градиента из пакета опыта. Базовая скорость обучения равна $3 \cdot 10^{-4}$. После 128 начальных переходов выполняется одно обновление на каждый переход, всего 99 872. У непрерывных методов коэффициент мягкого обновления целей равен 0,005; у DQN действуют

указанные выше периодические обновления. Физика, интегратор, R1 и семантика запросов общие (Приложение В).

Фиксированный бюджет сравнивает процедуры при одинаковом числе взаимодействий, но не при одинаковом вычислительном времени и не при достигнутой сходимости. У TQC дополнительные квантильные прогнозы меняют объём вычислений; равенство числа переходов не задаёт равенства стоимости обучения. В сериях использовалось параллельное исполнение независимых обучений; сумма длительностей процессов не является временем всей серии. Системные диагностические пилоты и замеры производительности не входят в 33 обучения Таблицы 2.

Таблица 2 – Состав анализируемых серий и назначение данных

Серия	Что сравнивается	Обучений	Оценочные старты
Основная	SAC/TQC/DDPG/DQN с фильтром; сопоставимый SAC без него, seed 0–2	15	20 валидационных + 3 именованных
Stage 1	Два изменения DDPG-on и SAC-off, seeds 0–2	12	Прежние 20 + 3
Confirmation	Фиксированные warmup5000, новые seeds 3–5	6	Прежние 20 + 3
Robustness	Шесть лучших исходных политик и классика, исполнение off/on	0	140 новых: 7 групп

3.3 Выбор контрольной точки и проверка настройки

Через каждые 10 000 обучающих переходов, включая исходную и конечную модели, проводится детерминированная оценка на 20 фиксированных validation-состояниях из (11). Ещё три именованных сценария (*named*) задают точное нижнее положение и $\theta_0 = \pm 0,02$ при остальных нулевых координатах. Они описательные и никогда не входят в выбор.

Лучшей точкой (*best*) называется сохранённая модель, максимизирующая лексикографический ключ: сначала сравнивается первая компонента, при равенстве — следующая

$$K_{\text{ckpt}} = (p, \overline{H}_f, \overline{H}_\ell, -\bar{t}_{\text{first}}, n). \quad (12)$$

В (12) p — доля успеха на validation20, черта означает среднее, t_{first} — начало первого подтверждённого интервала удержания длиной не менее 2 с (среднее по эпизодам, где он есть), n — число обучающих переходов. Если такого интервала нет ни в одном эпизоде, вместо среднего времени используется 11 с. При равных физических метриках выбирается более поздняя контрольная точка. Возврат в ключ не входит. Последней точкой (*last*) называются веса после 100 000 переходов. Best и last относятся к одному обучению; их оценки не являются независимыми повторениями эксперимента.

Внешняя оценка сохранённых best/last выполняется при обоих режимах фильтра на тех же 23 стартах: $2 \times 2 \times 23 = 92$ слота на обучение. Классика имеет 46. Это проверка сохранённых моделей и вмешательства в их исполнение, но не независимая оценка обобщения: validation уже использована в выборе.

Stage 1 меняет ровно одно значение относительно baseline: либо начальный сбор опыта $128 \rightarrow 5000$ (warmup5000), либо скорость обучения $3 \cdot 10^{-4} \rightarrow 10^{-4}$ (lr1e4). Во втором случае

остаётся 99 872 обновления, в первом — 95 000. Смена `warmup` затрагивает последовательность опыта и число обновлений, поэтому одна изменённая настройка не означает один изолированный причинный механизм.

Настройка выбирается по трём `seeds` и только валидации лучшей точки в режиме соответствующего обучения:

$$K_{\text{cfg}} = (\min_i p_i, \text{mean}_i p_i, \min_i \bar{H}_{f,i}, \text{mean}_i \bar{H}_{f,i}, \text{mean}_i \bar{H}_{\ell,i}). \quad (13)$$

По (13) требуется строгое улучшение исходной настройки; при равенстве сохраняется базовый вариант. Для SAC-off используется оценка off, а улучшение от включения фильтра при оценке в этот ключ не подставляется.

Выбранные настройки затем без изменений проверяются на новых значениях `seed` 3, 4, 5. Предварительно закреплённый критерий `confirmation`: каждый новый `best` имеет $p \geq 0,8$ (не менее 16/20), не менее двух из трёх `last` также имеют $p \geq 0,8$, все задания и оценки завершены. Это правило принятия проекта, а не статистический тест с заданной вероятностью ошибки. Новые значения `seed` проверяют повторяемость обучения; старты оценки остаются прежними и не становятся независимыми от отбора.

3.4 Что проверяют данные и что разработано в проекте

Сравнение опирается на сохранённые конфигурации и контрольные точки, сводки обучения и журналы оценки. Это позволяет связать показатели с конкретным запуском и проверить применение правил отбора. В электронном приложении представлены компактные таблицы, выбранные модели SAC/TQC и инструкции воспроизведения. Большие буферы опыта и полные архивы всех обучений в раздаточный комплект не входят.

Проверка сохранённых результатов и повторение эксперимента решают разные задачи. Пересчёт метрик по журналам устанавливает согласованность данных с определениями, но не воспроизводит динамику заново. Для повторного обучения нужны исходные настройки и программное окружение; даже при одинаковом `seed` численное поведение может зависеть от реализации. Полные временные ряды сохранены не для всех обучающих переходов, поэтому отсутствующие траектории не восстанавливаются по агрегатам.

В проекте разработаны исправленный интерфейс симулятора, слой событий рабочих ограничений, `Gymnasium`-обёртка, общий фильтр и его подключение, журналы, повторяемое исполнение и анализ. Лабораторная динамика, базовые LQR/траекторные идеи и алгоритмы библиотек имеют самостоятельное происхождение. Вклад курсовой состоит в разработке экспериментальной цепочки и сравнительном анализе; создание с нуля физического симулятора или перечисленных алгоритмов обучения не заявляется.

Итог протокола — сравнение разных источников изменчивости без смещения знаменателей. Эпизод, уникальный физический старт, `checkpoint` и независимый запуск обучения отвечают на разные вопросы. Следующие главы используют эту структуру при интерпретации результатов.

4 Качество обучения и проверка повторяемости

4.1 Какие решения найдены в основной серии

Все 15 обучений основной серии завершены: каждое содержит 100 000 переходов и 99 872 обновления. В Таблице 3 режим оценки совпадает с режимом обучения, а значения относятся только к двадцати валидационным состояниям. Поэтому SAC-off не оценивается здесь с незаявленной дополнительной защитой.

Таблица 3 – Основная серия: успехи лучших / последних весов из 20

Конфигурация	Seed 0	Seed 1	Seed 2
SAC-on	20 / 20	20 / 20	20 / 20
TQC-on	20 / 20	20 / 20	20 / 20
DQN-on	20 / 11	14 / 14	20 / 20
DDPG-on	20 / 20	0 / 0	0 / 0
SAC-off	0 / 0	0 / 0	0 / 0
Классика	20/20 при off и on; без обучения		

Источник: Результаты вычислительных экспериментов автора; валидационные состояния, именованные исключены.

SAC-on и TQC-on находят успешные лучшие модели и сохраняют успех последних весов во всех трёх запусках. Метрика насыщена, поэтому по этим данным нельзя установить безусловное превосходство одного над другим. DQN и особенно DDPG заметнее зависят от seed. У DQN seed 0 последние веса хуже выбранных: 11 против 20 успехов. Исходный SAC-off не решает задачу ни в одном запуске. Это результат конкретного бюджета и настроек, а не невозможность управления без фильтра.

Три именованных сценария рассматриваются отдельно. Для best SAC-on и TQC-on каждый seed имеет 3/3; DQN-on — 3/3, 2/3, 3/3; DDPG-on — 3/3, 0/3, 0/3; SAC-off — нули. Отсюда происходят описательные числа 23/23 и 16/23 старых сводок. Они не заменяют знаменатель выбора из 20 состояний.

Кривые на Рисунке 5 показывают, что одинаковый бюджет приводит к разным траекториям качества. Каждая точка — оценка сохранённой модели, а отрезок лишь соединяет соседние измерения: между ними качество не измерялось. Потеря качества к концу обучения обосновывает раздельное хранение лучших и последних весов.

4.2 Два разных сравнения фильтра

Сопоставимая пара обучения SAC-on/off имеет одинаковые базовые настройки и seeds, но разные переходы среды из-за защиты. Успехи 20/20 против 0/20 на каждом seed свидетельствуют о преимуществе изученной процедуры обучения on в данном протоколе. При этом режим меняет фактический опыт, длительности эпизодов и дальнейшую случайную последовательность. Нельзя приписать весь эффект одному из этих механизмов или объявить его универсальным для SAC.

Другой эксперимент исполняет *одни и те же веса* с фильтром и без него. У best SAC-on seed 1, TQC-on seeds 0 и 1, DDPG-on seed 0 и всех трёх DQN-on выключение защиты снижает validation-успех до нуля. У best SAC-on seeds 0 и 2 и TQC-on seed 2 защита на этих стартах не вмешивается:




Рисунок 5 – Успех на двадцати валидационных состояниях в основной серии. Фильтр при периодической оценке соответствует режиму обучения; каждый seed показан отдельно. Повторные ссылки на одну и ту же оценку исключены.

оба режима дают 20/20. Полная матрица находится в Приложении А. Это показывает зависимость исполнения от защитного слоя. Даже нулевая доля вмешательств при оценке не означает, что фильтр не повлиял на обучение.

Для классики оба режима успешны в 23/23 описательных сценариях, но off в 21 из них превышает желаемые 0,24 м без события на 0,25 м. Таким образом, один и тот же исходный успех допускает разные характеристики безопасности. На 713 внешних on-слотах основной серии аудит не нашёл превышений 0,24 м, событий положения и отказов фильтра. Эти слоты включают разные метки best/last и повторные старты; их нельзя трактовать как 713 независимых испытаний надёжности.

4.3 Ограниченный подбор: победа по правилу и границы объяснения

Stage 1 содержит 12 новых обучений: DDPG-on и SAC-off, по два однофакторных кандидата и три значения seed. Таблица 4 даёт результаты best в режиме соответствующего обучения. Базовый вариант взят из основной серии без повторного обучения.

Таблица 4 – Stage 1: успехи best из 20, seeds 0 / 1 / 2

Настройка	DDPG-on, оценка on	SAC-off, оценка off
Базовая настройка	20 / 0 / 0	0 / 0 / 0
Скорость обучения 10^{-4}	0 / 13 / 0	0 / 0 / 0
Начальный сбор 5000 переходов	0 / 20 / 20	20 / 0 / 0

Источник: Результаты вычислительных экспериментов автора; валидационные состояния, именованные исключены.

По заранее заданному правилу (13) вариант с начальным сбором 5000 переходов (warmup5000) — строгий вариант с лучшим ключом в обеих группах. Минимальный успех остаётся нулевым; решает следующая компонента: средняя доля для DDPG растёт с $1/3$ до $2/3$, для SAC-off — с 0 до $1/3$. Точные ключи сохранены в электронных материалах, округлённые приведены в Приложении Б. Вариант 10^{-4} базовый вариант не улучшает. Эти выводы не позволяют назвать DDPG или SAC-off устойчивыми к seed.

У DDPG warmup5000 seed 1 успех достигает 20/20 на 80 и 90 тыс. переходов, затем падает до 0/20 на 100 тыс. переходов. Seed 2 после промежуточных провалов сохраняет 20/20 на 80–100 тыс. переходов. У SAC-off выигрыш сосредоточен в seed 0: best даёт 20/20, last — 17/20 при off. Seeds 1 и 2 не приобретают двухсекундного удержания. Одна улучшенная средняя величина поэтому не описывает всю процедуру.

Диагностическая гипотеза увеличенного начального сбора предполагала улучшение раннего исследования верхней области. К 20 тыс. переходов доля таких образцов улучшилась у всех трёх запусков DDPG, но только у одного из трёх запусков SAC-off; заранее требовалось не менее двух. Следовательно, *победа SAC-off warmup5000 по итоговому ключу не подтверждает заявленный ранний механизм*. Для DDPG признаки поддерживают гипотезу, но не изолируют её: меняются данные, случайная последовательность и число обновлений. Переоценивание критика, недостаточная сеть или недостаток переходов как причины не доказаны.

4.4 Подтверждение на новых значениях seed

Все шесть новых обучений warmup5000 и шесть внешних оценок завершены. Каждое обучение имеет 100 000 переходов и 95 000 обновлений. При неизменных параметрах best DDPG-on на seeds 3/4/5 даёт 4/0/20 успехов из 20, last — 0/0/0. SAC-off даёт нули у лучших и последних весов во всех трёх случаях. Обе конфигурации не проходят закреплённый критерий: не каждый best достигает 16/20 и нет двух успешных last.

Рисунок 6 сохраняет различие между seeds отбора и проверки. Отрицательный результат относится к корректно завершённой серии: он не вызван пропущенными заданиями. Он не отменяет правильность применения правила Stage 1, но ограничивает практическую ценность выбранного улучшения. Дополнительный бюджет автоматически не добавлялся.




Рисунок 6 – Warmup5000 на seeds 0–5: лучшие и последние веса на двадцати валидационных состояниях в режиме обучения. Вертикальная линия отделяет Stage 1 от confirmation; горизонтальный пунктир — порог 16/20.

4.5 Маятник сверху: почему это ещё не успех

В журналах last DDPG-on confirmation seeds 3 и 5 все двадцать validation-эпизодов в последние две секунды удовлетворяют углу, угловой скорости и координате из (8). Однако скорость тележки выходит за 0,20 м/с и прерывает удержание. Из 4020 отсчётов последних двух секунд скорость допустима в 1925/4020 (47,89%) для seed 3 и в 2404/4020 (59,80%) для seed 5. Это доли отсчётов двадцати траекторий, не доли успешных эпизодов. Это установленное нарушение компоненты критерия, а не только визуальное впечатление от анимации.

Для seed 3 средний возврат от best к last растёт с 273,68 до 706,05, в то время как успех падает с 4/20 до 0/20, а среднее заключительное удержание — с 0,8895 до 0,3325 с. У seed 5 успех падает с 20/20 до 0/20, удержание — с 7,8915 до 0,0115 с. Конкретная пара сохранённых траекторий seed 5 показана на Рисунке 7; в этом примере возврат, напротив, снижается. Два наблюдения не следует смешивать. Синхронное воспроизведение этой пары доступно в видеоприложении 2: последние веса визуальнo держат маятник около верха, но не обеспечивают допустимую скорость тележки.




Рисунок 7 – DDPG-on warmup5000, seed 5, validation_1000, оценка on: best 90k и last 100k. На заключительных двух секундах угол допустим, но last пересекает порог скорости. График построен по сохранённым состояниям двух эпизодов.

Расхождение возврата и успеха согласуется с их определениями: при $v = 0,30$ м/с множитель $q(v/2) \approx 0,978$ ещё близок к единице, хотя жёсткий порог скорости удержания уже нарушен. Награда суммируется по всему эпизоду, а успех требует заключительного двухсекундного интервала. Это объясняет различие метрик, но не причину изменения весов актора или критика. У других неудачных запусков и траекторий возможны иные механизмы; отдельный ролик не доказывает общего механизма ухудшения DDPG.

Результат главы двойственен: в основной серии получены работающие SAC/TQC с фильтром, но качество обучения не одинаково воспроизводится у всех методов. Настройка, выигравшая отбор на этапе разработки, не прошла проверку на новых запусках. Поэтому дальнейшая оценка фиксированных политик должна исследовать физические старты отдельно от повторяемости обучения.

5 Структурированная проверка начальных условий

5.1 Что изменяется, а что остаётся фиксированным

После анализа обучения проведена завершённая диагностическая проверка на этапе разработки (*structured robustness*). В ней нет новых обучений. Оцениваются шесть закреплённых лучших контрольных точек исходной основной серии: SAC-on и TQC-on с seed 0–2, а также прежний классический контроллер. Контрольные точки SAC выбраны на 70/50/80 тыс. переходах, TQC — на 80/40/70 тыс. Контрольные суммы весов и номинальной траектории закреплены до новых исходов (Приложение В).

В этой главе *off/on* означает только режим исполнения одной политики, обученной с фильтром. SAC-off из предыдущей главы в матрицу не входит. DQN и DDPG также не включены: это ограниченный протокол диагностики выбранных исходных SAC/TQC и классики, а не полное повторное сравнение всех пяти методов. Их robustness-результаты из этого набора вывести нельзя.

Семь групп содержат по 20 общих состояний, всего 140 уникальных стартов. Для каждого контроллера и режима используются те же точные координаты. Матрица имеет 7 контроллеров $\times$ 2 режима $\times$ 7 групп = 98 заданий по 20 эпизодов, то есть 1960 эпизодов и 980 полных пар. Дополнительные технические замеры времени исполнения не входят в эти показатели.

5.2 Дизайн стартов и отношение к распределению обучения

В Таблице 5 заданы все группы. Используются $B = \sqrt{2AL} \approx 1,385638$ м/с — масштаб центральной скорости торможения — и $N = \sqrt{g/l} \approx 7,378648$ рад/с — естественный частотный масштаб. Это мотивированные моделью масштабы дизайна, а не экспериментально доказанная область успешного подъёма.

Таблица 5 – Точные правила семи групп, по 20 состояний

Группа	Значения и генерация	Отношение к области обучающих стартов
Nominal	Независимые $x, v \in [-0,02, 0,02]$, $\theta, \omega \in [-0,05, 0,05]$, равномерно	То же распределение, новые 20 точек
Position	$x = \pm\{0,02; 0,04; 0,06; 0,08; 0,10; 0,12; 0,15; 0,18; 0,21; 0,23\}$ м	Смешанная: 2 точки на границе носителя, 18 вне по одной оси
Velocity	$v = \pm 0,95B k/10$, $k = 1, \dots, 10$; максимум 1,316356 м/с	Одноосевое внераспределительное отклонение
Angle	$\theta = \pm k\pi/11$, $k = 1, \dots, 10$; максимум 2,855993 рад	Одноосевое отклонение; верх точно не включён
Angular velocity	$\omega = \pm Nk/10$, $k = 1, \dots, 10$	Одноосевое отклонение
Boundary	$x = \pm a$, $a \in \{0,20; 0,23\}$ м; $v = \text{sign}(x)q\sqrt{2A(L-a)}$, $q \in \{0,25; 0,5; 0,75; 0,9; 0,99\}$	Движение наружу у границы; вне прямоугольника по x, v
Joint	$s_k = (k/10) \text{diag}(0,18; 0,6; \pi; N)z_k$, $z_k \sim U([-1, 1]^4)$, и $-s_k$	Совместное отклонение по нескольким координатам

Источник: Зафиксированный дизайн экспериментов автора. В одноосевых группах остальные координаты нулевые; в Boundary $\theta = \omega = 0$. Точный список — в электронном приложении.

Случайные значения создавались единственным PCG64 seed 2026091601: сначала 20 nominal-векторов, затем 10 joint-векторов; сетки случайный поток не расходуют. Joint включает зеркальные пары и растущий масштаб, поэтому это не независимая равномерная выборка из большого прямоугольника. Все координаты в SI, угол отсчитывается от нижней вертикали и в исходных данных не оборачивается.

Все 140 стартов удовлетворяют (4). У Boundary $q < 1$ оставляет тормозной запас. Для Joint даже верхняя оценка $0,18 + 0,6^2/(2A) = 0,225 < L$ гарантирует выполнение позиционных условий отбора. Отбрасывания по результатам контроллера и подрезания координат нет. Тем не менее выбор только K ограничивает область сравнения: не исследуются старты, допустимые для off-reset по рабочему прямоугольнику, но отвергаемые on-reset.

Носитель (support) распределения (11) — совместный четырёхмерный прямоугольник, то есть множество совместно допустимых значений четырёх координат. Две Position-точки $x = \pm 0,02$, остальные координаты нуль, лежат на границе его замыкания, но детерминированная осевая пара не имеет того же распределения, что обучающие старты. Остальные 18 Position и все Velocity, Angle, Angular velocity выходят за этот прямоугольник по одной оси. Все Boundary выходят по двум осям. Среди Joint две точки выходят по двум координатам, десять — по трём, восемь — по четырём. Это конкретная внераспределительная диагностика, а не проверка глобальной устойчивости равновесия.

5.3 Сначала исходная задача: новые nominal-состояния

На новых nominal-стартах в режиме on SAC имеет 60/60 успешных исполнений, TQC — 59/60, классика — 20/20. Каждое RL-семейство здесь использует три политики на *одних и тех же двадцати состояниях*; речь не о 60 независимых физических стартах. У TQC seed 1 один nominal-эпизод неуспешен, поэтому все 140 исполнений семи контроллеров дают 139 успехов.

Это проверка из того же исходного распределения на другом фиксированном наборе. Прежние 60/60 TQC на валидации и новые 59/60 на nominal не противоречат друг другу: validation использована для выбора best, nominal20 — другой набор. Новые nominal-результаты показывают перенос на исследованные близкие старты, но не гарантируют успех на всех точках даже малого прямоугольника. Видеоприложение 1 показывает три выбранных контроллера на общем nominal_00; это иллюстрация успешного движения, а не все двадцать стартов.

5.4 Где проявляются ограничения захвата

Рисунок 8 сохраняет все семь контроллеров и семь групп. Он отвечает на вопрос, одинаково ли меняется качество при разных видах отклонения. Число успешных on-эпизодов из 140 в каждой группе: Nominal 139, Position 122, Velocity 109, Angle 102, Angular velocity 111, Boundary 97, Joint 116. Наиболее трудной по этому равновзвешенному дизайну оказывается Boundary; это свойство выбранных точек и политик, а не универсальный порядок трудности всех возможных возмущений.

На всех 140 стартах SAC-on seeds 0/1/2 имеет 135/129/128 успехов, TQC-on — 127/93/99, классика — 85. Таким образом, одинаковый полный успех на старом validation не устранил различия между значениями seed обучения при расширении стартов. По семействам успех off →




Рисунок 8 – Полная матрица успеха фиксированных контроллеров: каждое число из 20 общих состояний группы. Off/on — исполнение одних весов. Таблица цветов дополнена числами для чтения в чёрно-белой печати.

on меняется так: SAC — 279/420 → 392/420, TQC — 101/420 → 319/420, классика — 61/140 → 85/140. Знаменатели соответствуют числу исполнений, а не числу независимых обучений. Не следует скрывать неоднородность TQC его средним или трактовать эти доли как вероятности реального применения.

Включение защиты помогает не монотонно на каждом старте. Например, у SAC seed 2 в группе Angular velocity успех уменьшается с 18/20 до 16/20. У классики Boundary остаётся 10/20 в обоих режимах. Наличие фильтра само по себе не обеспечивает новый механизм захвата: он меняет вход тележки, вслед за которым меняется и движение маятника. В этом наборе оценивается прежний классический план с однократным переключением, без перепланирования под каждый старт. Видеоприложение 5 показывает по одному выбранному старту семи групп для SAC seed 0, а видеоприложение 6 — все семь контроллеров на joint_00. Все эти выбранные примеры успешны; неоднородность полной серии видна из таблиц и Рисунка 8.

5.5 Парное вмешательство: безопасность и задача

В Таблице 6 четыре разных результата оставлены отдельными. Суммарный успех увеличивается с 441/980 до 796/980, то есть с 45,00% до 81,22% (на 36,22 процентного пункта). Успех без превышения с допуском возрастает с 394/980 до 796/980, на 41,02 п.п. Разница между 441 и 394 — 47 успешных off-эпизодов, в которых всё же превышалась желаемая граница.

Во всех 980 on-эпизодах достигнут горизонт, превышений желаемой границы с допуском нет. Однако 184/980 эпизода (18,78%) не выполняют заключительное удержание. Сохранение тележки в области само по себе не решает задачу подъёма и захвата. Из этих агрегатов нельзя

Таблица 6 – Robustness: исходы по всей фиксированной матрице

Показатель	Off, из 980	On, из 980
Исходный успех задачи	441	796
Успех без превышения с допуском	394	796
Превышение с допуском $\pm 0,24$ м	585	0
Достижение горизонта	446	980
Горизонт без заключительного удержания	5	184
Событие position_limit на $\pm 0,25$ м	534	0
Событие velocity_limit	0	0

Источник: Результаты вычислительных экспериментов автора. Числа строгих превышений и превышений с допуском здесь совпадают; определения различаются.

приписать всем 184 ту же причину, что установлена для отдельных DDPG-траекторий в предыдущей главе: DDPG вообще не входит в эту robustness-матрицу.

В 980 парных исходах оба режима успешны 434 раза, только on — 362, только off — 7, ни один — 177. Во всех семи парах с успехом только без фильтра есть превышение с допуском желаемой границы. Поэтому они не являются примерами утраты *успеха без превышения*, хотя являются реальной утратой исходного успеха. Рисунок 9 показывает обе стороны этого результата. Видеоприложение 3 иллюстрирует устранение остановки по положению; видеоприложение 4 — успех off с превышением желаемой границы и отсутствие успеха on без превышения. Оба примера выбраны по зафиксированному правилу, а не являются случайной выборкой.




Рисунок 9 – Слева — отдельные метрики по 980 эпизодам каждого режима; справа — взаимоисключающие исходы 980 пар. Части слева пересекаются и не должны суммироваться до 100%.

Сравнение условно причинно интерпретируемо как эффект включения *всего слоя исполнения* на данных фиксированных весах и стартах: checkpoints, физика и критерии не заменялись. На уровне программного интерфейса меняются также допуск начального состояния и возможность терминального отказа фильтра. Фактически все 140 стартов были допущены в обоих режимах, а отказов фильтра в 1960 эпизодах не было. Поэтому различие состава начальных состояний и новый тип отказа не создают наблюдаемый разрыв исходов в этих парах. Реальные

прекращения, однако, различаются: 534 off-эпизода остановились по позиции, все on дошли до горизонта. Это часть эффекта исполнения и не основание сравнивать возврат как будто все траектории имели одинаковую длительность.

Общие доли используют равные веса семи групп и веса контроллеров 3 SAC + 3 TQC + 1 классика. Это веса исследовательского дизайна. Сетки и зеркальные пары не образуют независимую случайную выборку из всего пространства, поэтому p-values, доверительные интервалы глобального успеха и перенос на практические частоты стартов не приводятся.

5.6 Насколько часто фильтр меняет запрос

Таблица 7 агрегирует вмешательства по числу принятых решений. Всего on изменил 115 355 из 980 000 решений, то есть 11,7709%; отказов нет. При off показатель неприменим. Небольшая доля не означает слабого эффекта: одно раннее торможение может изменить все последующие состояния и обратную связь. Но по одному агрегату нельзя установить момент, ответственный за конкретный исход.

Таблица 7 – Коррекции запросов в robustness, режим on

Семейство	Изменено / принято	Доля, %	Средняя / max $ \Delta u $, м/с ²
SAC, три seed	4209 / 420000	1,00	2,30 / 7,99
TQC, три seed	57179 / 420000	13,61	4,65 / 8,00
Классика	53967 / 140000	38,55	74,70 / 394,64

Источник: Результаты вычислительных экспериментов автора. Средняя величина коррекции рассчитана только среди вмешательств, с суммированием числителей.

В отличие от запроса обучаемой политики, исходный запрос классики может превышать предел ускорения; величина коррекции включает приведение амплитуды к ± 4 м/с². Поэтому значения 74,70 и 394,64 не означают приложение таких ускорений и не измеряют исключительно дополнительное торможение по x/v . Сравнить их с SAC/TQC как прямую меру «худшего качества защиты» неправильно.

Для классики сохраняется различие между заявленным и фактически использованным программным интерфейсом среды. В сохранённой спецификации указан контракт среды обучения SAC, тогда как классический исполнитель использует другой интерфейс. Проверка полных журналов подтвердила совпадение физики, интегратора, награды и критерия удержания. Поэтому соответствующие физические показатели сопоставимы, но полная тождественность наблюдений и пути формирования запросов не установлена. Подробности расхождения сохранены в документации репозитория.

Завершённая серия показывает перенос на новые nominal-старты и конкретные пределы захвата при структурированных отклонениях. При robustness-проверке веса не изменялись: те же политики оценивались при других начальных условиях. Наблюдаемое снижение успеха относительно nominal характеризует их поведение на выбранных группах; этот эксперимент не устанавливает причины ограниченного обобщения. Это диагностика на этапе разработки; если её используют для изменения метода, она не станет независимым финальным тестом нового метода.

Заключение

В одной симуляционной постановке исследованы классический подъём со стабилизацией и четыре метода обучения с подкреплением. Явно зафиксированы ускорительный вход, рабочие ограничения, интервал управления, награда и физический критерий.

Основная серия отвечает на вопрос о достижимости рабочего решения при выбранном бюджете. SAC-on и TQC-on дают 20/20 на validation для best и last всех трёх seeds. DQN способен находить успешное решение, но отдельные seeds и последние веса хуже. DDPG-on успешен только на одном исходном seed, SAC-off с базовыми настройками не достигает успеха. Эти результаты характеризуют конкретные процедуры на исходной узкой области; validation использована при выборе и не является независимым итоговым тестом.

Однофакторный подбор показывает ограниченность улучшения настройки. Warmup5000 строго выигрывает Stage 1 для DDPG-on и SAC-off, но минимум успеха по seeds остаётся нулевым. Обе настройки не проходят confirmation на seeds 3–5. У SAC-off предположение об улучшении раннего покрытия верха также не получает поддержки по заранее закреплённому критерию.

Сохранённые DDPG-журналы устанавливают конкретное расхождение между наградой и удержанием: верхнее положение сохраняется, но скорость тележки прерывает требуемый интервал. В одном seed это сочетается с ростом суммарной награды. Такая диагностика объясняет, почему визуальное положение маятника и скалярная награда недостаточны, но не устанавливает причину деградации параметров нейросети.

Завершённая структурированная проверка начальных условий оценивает новые старты без новых обучений. На nominal20 фиксированные SAC/TQC и классика почти полностью воспроизводят решение исходной задачи; на осевых, граничных и совместных отклонениях возникают различия между политиками, скрытые прежней валидацией. На всей фиксированной матрице фильтр повышает успех с 441/980 до 796/980 и устраняет наблюдаемые превышения 0,24 м с учётом допуска. При этом 184/980 эпизода он достигают горизонта без этих превышений, но не выполняют заключительное удержание. Измеренный парный эффект относится к 140 выбранным состояниям из K и закреплённым контроллерам, а не ко всей области K ; это не доказательство универсальной безопасности или превосходства на произвольных состояниях.

Практический результат работы — воспроизводимая картина сильных и слабых сторон конкретных процедур, включая отрицательные исходы. Она позволяет обоснованно отделить задачу защиты тележки от задачи захвата маятника и повторяемость обучения от чувствительности фиксированной политики к старту. Неизвестными остаются общая область захвата, распределение качества по будущим seeds, устойчивость к неопределённости модели и перенос на оборудование. Такие выводы требуют новых данных.

Перспективы работы — независимая оценка зафиксированной процедуры на новых стартах и большем числе обучений, перепланирование классического подъёма, а также учёт задержек, шумов и ошибок исполнения ускорения. Закрытый набор итоговой оценки не использовался. Перенос на оборудование требует отдельной проверки модели и привода.

Список использованных источников

- [1] Haarnoja T., Zhou A., Abbeel P., Levine S. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor // Proceedings of the 35th International Conference on Machine Learning. PMLR. 2018. Vol. 80. P. 1861–1870. URL: <https://proceedings.mlr.press/v80/haarnoja18b.html> (дата обращения: 17.09.2026).
- [2] Haarnoja T., Zhou A., Hartikainen K. et al. Soft Actor-Critic Algorithms and Applications. Препринт arXiv:1812.05905v2. Версия 2, 2019. URL: <https://arxiv.org/abs/1812.05905v2> (дата обращения: 17.09.2026).
- [3] Henderson P., Islam R., Bachman P., Pineau J., Precup D., Meger D. Deep Reinforcement Learning that Matters. Препринт arXiv:1709.06560v3. Версия 3, 2019. URL: <https://arxiv.org/abs/1709.06560v3> (дата обращения: 17.09.2026).
- [4] Kuznetsov A., Shvechikov P., Grishin A., Vetrov D. Controlling Overestimation Bias with Truncated Mixture of Continuous Distributional Quantile Critics // Proceedings of the 37th International Conference on Machine Learning. PMLR. 2020. Vol. 119. P. 5556–5566. URL: <https://proceedings.mlr.press/v119/kuznetsov20a.html> (дата обращения: 17.09.2026).
- [5] Lillicrap T. P., Hunt J. J., Pritzel A., Heess N., Erez T., Tassa Y., Silver D., Wierstra D. Continuous Control with Deep Reinforcement Learning. Препринт arXiv:1509.02971v6. Версия 6, 2019. URL: <https://arxiv.org/abs/1509.02971v6> (дата обращения: 17.09.2026).
- [6] Mnih V., Kavukcuoglu K., Silver D. et al. Human-level Control through Deep Reinforcement Learning // Nature. 2015. Vol. 518. P. 529–533. DOI: [10.1038/nature14236](https://doi.org/10.1038/nature14236).
- [7] Raffin A., Hill A., Gleave A., Kanervisto A., Ernestus M., Dormann N. Stable-Baselines3: Reliable Reinforcement Learning Implementations // Journal of Machine Learning Research. 2021. Vol. 22, no. 268. P. 1–8. URL: <https://jmlr.org/papers/v22/20-1364.html> (дата обращения: 17.09.2026).
- [8] Robotics Laboratory. Cart-pole. Исходный лабораторный репозиторий, ветка linear-stable. URL: <https://github.com/robotics-laboratory/cart-pole>. (дата обращения к странице репозитория: 17.09.2026).
- [9] Stable-Baselines Team. TQC — SB3-Contrib Documentation. Документация версии 2.9.0. URL: <https://sb3-contrib.readthedocs.io/en/v2.9.0/modules/tqc.html> (дата обращения: 17.09.2026).
- [10] Tedrake R. Underactuated Robotics. Chapter 8: Linear Quadratic Regulators. MIT, электронный учебный текст. URL: <https://underactuated.mit.edu/lqr.html> (дата обращения: 17.09.2026).

- [11] Tedrake R. Underactuated Robotics. Chapter 10: Trajectory Optimization. MIT, электронный учебный текст. URL: <https://underactuated.mit.edu/trajopt.html> (дата обращения: 17.09.2026).
- [12] Wabersich K. P., Zeilinger M. N. A Predictive Safety Filter for Learning-Based Control of Constrained Nonlinear Dynamical Systems. Препринт arXiv:1812.05506v4. Версия 4, 2021. URL: <https://arxiv.org/abs/1812.05506v4> (дата обращения: 17.09.2026).
- [13] Yuan Z., Hall A. W., Zhou S., Brunke L., Greeff M., Panerati J., Schoellig A. P. Safe-control-gym: A Unified Benchmark Suite for Safe Learning-Based Control and Reinforcement Learning in Robotics. Препринт arXiv:2109.06325v4. Версия 4, 2022. URL: <https://arxiv.org/abs/2109.06325v4> (дата обращения: 17.09.2026).

Приложение А. Полная матрица валидации основной серии

Таблица 8 содержит результаты внешней оценки сохранённых моделей. Все значения — число успехов из 20; named3 сюда не входят. On/off в названии конфигурации относится к обучению, в столбцах — к исполнению сохранённых весов. Классика имеет 20/20 в обоих режимах, а best/last к ней не применяются.

Таблица 8 – Best/last и режим исполнения; validation20

Конфигурация	Seed	Best on	Best off	Last on	Last off
SAC-on	0	20	20	20	0
SAC-on	1	20	0	20	0
SAC-on	2	20	20	20	20
TQC-on	0	20	0	20	0
TQC-on	1	20	0	20	0
TQC-on	2	20	20	20	0
DQN-on	0	20	0	11	0
DQN-on	1	14	0	14	0
DQN-on	2	20	0	20	0
DDPG-on	0	20	0	20	0
DDPG-on	1	0	0	0	0
DDPG-on	2	0	0	0	0
SAC-off	0	0	0	0	0
SAC-off	1	0	0	0	0
SAC-off	2	0	0	0	0

Показатель относится к выбранным 20 состояниям и не оценивает вероятность успеха на всём пространстве. Лучшие и последние веса относятся к одному обучению и не являются независимыми повторениями эксперимента. Совпадение показателей не означает совпадения весов. Внешние оценки не изменяют веса.

Приложение Б. Ключи выбора настройки

Таблица 9 иллюстрирует применение (13). Для формального сравнения использованы полные числа из материала «Точные ключи выбора настройки»; округление ниже служит только чтению. Все компоненты рассчитываются по валидационным состояниям для лучших моделей в режиме обучения, с учётом всех трёх seed. Именованные сценарии исключены.

Таблица 9 – Ключи Stage 1, округлённые до шести знаков

Вариант	$\min p$	$\text{mean } p$	$\min H_f$	$\text{mean } H_f$	$\text{mean } H_\ell$
DDPG baseline	0	0,333333	0	2,338500	2,338500
DDPG lr1e4	0	0,216667	0	0,924833	0,927167
DDPG warmup5000	0	0,666667	0	4,705000	4,705000
SAC-off baseline	0	0	0	0	0,073667
SAC-off lr1e4	0	0	0	0	0,001333
SAC-off warmup5000	0	0,333333	0	2,011333	2,126167

Строгий выигрыш warmup5000 установлен на второй компоненте и не зависит от округления длительностей. Это решение об ограниченной последующей проверке, не признание настройки надёжной. Confirmation сохранило требование: каждый новый best $\geq 16/20$, минимум два новых last $\geq 16/20$, параметры неизменны, неудачные seeds публикуются. Данные seeds 3–5 отвергли подтверждение обеих конфигураций.

Приложение В. Состав и воспроизводимость электронных материалов

Электронные материалы дополняют отчёт данными и средствами проверки. Главная страница репозитория содержит переходы к коду, результатам, моделям, видеопримерам и инструкции запуска. Соответствие разделов исследования данным приведено в Таблице 10; точные пути, идентификаторы версий и контрольные суммы вынесены в документацию репозитория.

Таблица 10 – Материалы для проверки результатов исследования

Раздел	Содержание электронного приложения
Основная серия	Показатели лучших и последних моделей, история валидации, сравнение режимов исполнения.
Подбор настроек	Результаты вариантов по каждому seed, точные ключи отбора, проверка гипотезы о раннем исследовании.
Новые запуски	Результаты исходных и новых seed, проверка критерия подтверждения, разложение удержания на физические компоненты.
Начальные условия	Точные 140 стартов, результаты по контроллерам и группам, парные исходы, показатели вмешательств.
Модель и исполнение	Конфигурации динамики и среды, спецификация фильтра, шесть выбранных моделей SAC/TQC, инструкции запуска.

Компактные таблицы позволяют повторно проверить суммы, доли и применение правил выбора без обучения моделей. Для пересчёта всех метрик из исходных переходов требуются полные журналы, а для повторного исполнения — среда симуляции и сохранённый контроллер. Эти уровни воспроизводимости различаются. Большие исходные архивы и буферы опыта не входят в раздаточный комплект; шесть моделей SAC/TQC предназначены для исполнения и не заменяют данные для возобновления всех прежних обучений. Выбранные веса DDPG и DQN в комплект не включены.

Исходники отчёта и команды сборки позволяют получить PDF с теми же таблицами и рисунками. Основной текст набран Times New Roman; для самостоятельной сборки этот шрифт должен быть установлен. Технические сведения о происхождении данных, прежних редакциях и проверках сохранены отдельно, чтобы они не затрудняли чтение научного текста.

Лабораторная модель и исходная классическая основа заимствованы с указанием источника. SAC, TQC, DDPG и DQN использованы в библиотечных реализациях. Происхождение заимствований и характер помощи при подготовке материалов раскрыты в документации репозитория. Фотография на Рисунке 1 показывает реальную установку, иллюстрация на Рисунке 2 поясняет её узлы, а Рисунок 3 задаёт соглашения модели. Изображения не используются для извлечения измерений и не подтверждают аппаратных испытаний обученных политик.

Приложение Г. Видеопримеры сохранённых траекторий

Шесть роликов представлены на странице «Видео экспериментов» электронного приложения. Они созданы из принятых журналов без нового расчёта динамики и имеют фиксированное правило выбора. Таблица 11 отделяет иллюстрации от статистики серий. Шестой ролик, несмотря на исходное название, не относится к независимому итоговому тесту.

Таблица 11 – Видеоприложения: содержание и границы выводов

Материал	Сценарий и назначение
1. Исходная задача	Классика, SAC seed 0, TQC seed 0; on, общий nominal_00. Один выбранный успешный старт.
2. DDPG: лучшие и последние веса	Confirmation warmup5000 seed 5, validation_1000, on. Разные веса: 90 и 100 тыс. переходов; пример ограничения скорости при положении маятника около верха.
3. Предотвращение остановки	SAC seed 0, angle_01: off останавливается на 0,25 м, on завершает горизонт с успехом. Первая подходящая пара в закреплённом порядке.
4. Успех и граница	SAC seed 0, angle_16: off успешен с превышением 0,24 м, on неуспешен без превышения. Один из семи исходов «успех только off».
5. Семь групп стартов	SAC seed 0, on; индекс 00 каждой группы. Все выбранные примеры успешны; это не доля успеха группы.
6. Семь контроллеров	On, общий joint_00. Три SAC, три TQC и классика; все выбранные примеры успешны. Этот пример не относится к закрытому итоговому набору.

Видеопримеры показывают выбранные сохранённые траектории и не заменяют статистику серий. Для каждого ролика в репозитории указаны исходные эпизоды и правило отбора. Сохранены фактические времена движения; после окончания эпизода его панель останавливается. Интерполяция изображения между кадрами не используется при расчёте метрик, а краткое вмешательство фильтра может оказаться между кадрами. Поэтому численные выводы основаны на журналах, а не на визуальной оценке роликов.

Электронные материалы работы

Код и конфигурации, таблицы и графики, шесть видео, выбранные модели SAC/TQC, протоколы и инструкции воспроизведения доступны через главную страницу репозитория. Репозиторий закрытый (PRIVATE); необходимы авторизация и предоставленный владельцем доступ.

<https://github.com/nefedovdima/cartpole-coursework-submission>