

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа
«Прикладная математика и информатика»

Отчёт об исследовательском проекте на тему:

**Управление перевёрнутым маятником
методами обучения с подкреплением**

Выполнил:
студент группы БПМИ-233
Нефедов Дмитрий Львович

Руководитель проекта:
Бондарев Андрей Олегович
Эксперт Проектно-учебной
лаборатории робототехники
Факультет компьютерных наук НИУ ВШЭ

Москва, 2026

Содержание

Аннотация	3
Введение	4
1 Связанные работы и выбор подходов	7
1.1 Классическое управление как содержательная база сравнения	7
1.2 Четыре подхода к обучению управляющего закона	7
1.3 Защитный фильтр и достоверность сравнения	9
1.4 Позиционирование настоящего исследования	9
2 Модель, защитный фильтр и критерии качества	10
2.1 От установки к расчётной модели	10
2.2 Уравнения и постоянное управление между отсчётами	10
2.3 Наблюдение, запрос и фактически приложенное ускорение	12
2.4 Почему одной проверки положения недостаточно	13
2.5 Как фильтр выбирает команду	14
2.6 Награда и физический критерий успеха	15
2.7 Как измеряется безопасность	16
3 Обучение и правила сравнительного исследования	18
3.1 Обновление моделей и классическая обратная связь	18
3.2 Общие условия и единицы сравнения	19
3.3 Выбор контрольной точки и проверка настройки	20
3.4 Что проверяют данные и что разработано в проекте	21
4 Качество обучения и проверка повторяемости	23
4.1 Какие решения найдены в основной серии	23
4.2 Два разных сравнения фильтра	23
4.3 Ограниченный подбор: победа по правилу и границы объяснения	25
4.4 Подтверждение на новых значениях seed	26
4.5 Маятник сверху: почему это ещё не успех	26
5 Структурированная проверка начальных условий	28
5.1 Что изменяется, а что остаётся фиксированным	28
5.2 Дизайн стартов и отношение к распределению обучения	28
5.3 Сначала исходная задача: новые nominal-состояния	29
5.4 Где проявляются ограничения захвата	29
5.5 Парное вмешательство: безопасность и задача	31
5.6 Насколько часто фильтр меняет запрос	32
Заключение	34
Список использованных источников	36
Приложение А. Полная матрица валидации основной серии	38
Приложение Б. Ключи выбора настройки	39
Приложение В. Состав и воспроизводимость электронных материалов	40
Приложение Г. Видеопримеры сохранённых траекторий	41

Аннотация

Исследуется подъём маятника на тележке из нижней области и его последующее удержание сверху при ограничениях движения. В идеализированной модели с управляемым ускорением тележки сравниваются четыре алгоритма обучения с подкреплением и классический траекторный регулятор. Защитный фильтр проверяет запрос контроллера и при необходимости меняет ускорение, чтобы сохранить тормозной запас тележки. Успех удержания и соблюдение ограничений оцениваются отдельно.

Исследованы 33 обучения по 100 000 переходов: основная серия, ограниченный подбор настроек и их проверка на новых реализациях случайности. Два из изученных методов с фильтром решают все двадцать проверочных сценариев в трёх исходных обучениях. Увеличенный начальный сбор опыта улучшает результат отбора двух неуспешных процедур, но не проходит заранее установленный критерий подтверждения на новых обучениях. Показан случай роста суммарной награды при ухудшении удержания из-за скорости тележки.

Отдельно семь закреплённых контроллеров испытаны на 140 общих стартовых состояниях: 1960 эпизодов, 980 пар с фильтром и без него. Число успехов увеличивается с 441/980 до 796/980; наблюдаемые превышения желаемой границы с допуском исчезают. Однако 184/980 эпизода с фильтром не выполняют заключительное удержание, хотя достигают горизонта. Выводы относятся к фиксированному диагностическому набору и симуляции. Независимая итоговая оценка и аппаратные испытания не проводились.

Ключевые слова: перевёрнутый маятник; обучение с подкреплением; управление с ограничениями; защитный фильтр; повторяемость обучения; начальные условия; вычислительный эксперимент.

Введение

Перевернутый маятник на тележке — классический пример системы, где приводов меньше, чем степеней свободы. Привод перемещает тележку, а маятник вращается свободно: отдельного воздействия на его оси нет, и всё управление приходит к маятнику через движение шарнира. Чтобы поднять маятник из нижнего положения, ему нужно передать энергию раскачиванием. Вблизи верхнего неустойчивого равновесия задача становится другой: погасить угловую скорость и компенсировать отклонения. Связывает эти два этапа ограниченная длина направляющей — движение, полезное для подъёма, может не оставить тележке места для торможения.

Когда модель известна, задачу решают планированием траектории и обратной связью. Альтернативу даёт обучение с подкреплением, в котором управляющая программа улучшает поведение по опыту взаимодействия со средой. Наличие двух разных подходов и делает маятник удобным объектом сравнительного исследования. Практический вопрос при этом шире, чем «способен ли алгоритм однажды поднять маятник»: повторяется ли результат обучения, сохраняется ли он при других стартах и соблюдаются ли ограничения движения.

В обучении с подкреплением (reinforcement learning, RL) *агент* получает наблюдение и выбирает действие; правило такого выбора называется *политикой*. Среда исполняет действие и возвращает новое наблюдение вместе с численной *наградой*. Одну попытку управления — до заданного времени или до досрочной остановки — называют *эпизодом*. Агент обучается увеличивать накопленную награду, однако её рост не обязан означать выполнение физической задачи. Поэтому награда, успех удержания и соблюдение ограничений измеряются в работе отдельно.

Цель работы — исследовать качество подъёма и удержания перевернутого маятника классическим регулятором и выбранными методами обучения с подкреплением в общей модели с ограничениями. Объект исследования — система «тележка — маятник» с управляемым ускорением тележки. Предмет исследования — результативность управления, повторяемость обучения и чувствительность закреплённых контроллеров к начальным условиям и защитному фильтру.

Для достижения цели решаются следующие задачи:

1. свести модель, ограничения, наблюдение агента и физический критерий удержания в один явно заданный контракт эксперимента;
2. сравнить DQN, DDPG, SAC, TQC и классический траекторный регулятор в общих физических условиях и по общим правилам оценки, а методы обучения — дополнительно при одинаковом бюджете взаимодействий со средой, который к необучаемому классическому регулятору неприменим;
3. выяснить, переносится ли выигрыш ограниченного подбора настроек на новые запуски обучения;
4. оценить одни и те же закреплённые контроллеры на структурированном наборе начальных состояний в двух режимах фильтра;

5. разделить причины неуспеха по наблюдаемым признакам и очертить границы каждого вывода.

Сравнивать процедуры обучения сложнее, чем сравнивать готовые регуляторы, и следующие понятия нужны, чтобы различить источники изменчивости. Случайная инициализация нейросетей и случайный сбор опыта влияют на найденную политику; начальное значение генераторов случайных чисел (*seed*) задаёт конкретную реализацию этой случайности. Разные *seed* обучения при этом не меняют границы распределения начальных состояний — они меняют только ход самого обучения. Сохранённые параметры модели образуют *контрольную точку* (checkpoint), и в работе различаются лучшая по правилу отбора точка и последние веса того же обучения: это две версии одной модели, а не два независимых запуска.

Отбор модели опирается на *валидацию* — оценку на фиксированных состояниях, результаты которой участвуют в выборе. Такие состояния после этого нельзя считать независимым итоговым тестом. Проверка выбранной настройки на новых *seed* характеризует повторяемость обучения, но не заменяет испытание на новых физических стартах: это два разных вопроса, и в работе они разведены. Под *робастностью* здесь понимается эмпирическое сохранение качества при изменении начальных условий; устойчивость к шумам, задержкам и ошибкам параметров в эксперимент не входит.

Защитный фильтр проверяет запрос контроллера и при необходимости меняет ускорение, сохраняя тормозной запас тележки. Когда фильтр включён, оценивается уже не нейросеть, а связка «контроллер вместе с фильтром», и успех такой связки нельзя целиком приписать политике. Обратное тоже верно: защита положения сама по себе не поднимает маятник и не удерживает его. Именно поэтому сравнение ведётся в двух направлениях — между процедурами обучения и между двумя режимами исполнения одних и тех же весов.

Эксперименты образуют три серии обучения: основную из 15 запусков, этап подбора настроек из 12 и проверку выбранных настроек из шести. Каждый запуск содержит 100 000 переходов, суммарно 3,3 млн. Отдельно семь фиксированных контроллеров оценены на 140 общих стартовых состояниях, что даёт 1960 эпизодов и 980 пар «с фильтром и без него». Повторное использование одних и тех же стартов обеспечивает сопоставимость пар, но не превращает их в независимую выборку из всего пространства состояний.

Основные результаты. SAC и TQC с фильтром решают все двадцать валидационных сценариев в каждом из трёх исходных обучений. Увеличенный начальный сбор опыта для DDPG с фильтром и SAC без него улучшает результат отбора, однако последующую проверку повторяемости не проходит. В структурированной матрице включение фильтра увеличивает число успехов с 441/980 до 796/980 и устраняет наблюдаемые превышения желаемой границы с учётом допуска; при этом 184/980 эпизода завершают горизонт без успешного заключительного удержания. Последнее число и показывает главное различие работы — между допустимым движением тележки и выполнением полной задачи.

Вклад проекта — согласованная экспериментальная цепочка, построенная вокруг лабораторной модели, и сравнительный анализ полученных на ней результатов. В ходе работы созданы среда обучения с общим для всех методов путём команд, защитный слой с проверкой

тормозного запаса, обработка событий рабочих ограничений, протокол отбора моделей и средства анализа сохранённых журналов. Это позволило развести три источника изменчивости — фильтр, случайность обучения и начальное состояние — и сохранить отрицательные результаты наравне с положительными. Динамика лабораторной модели, классический регулятор и алгоритмы обучения заимствованы; новый универсальный алгоритм управления здесь не предлагается.

Работа выполнена в симуляции с идеально задаваемым ускорением. Обученные политики на оборудовании не испытывались, а независимая итоговая оценка после всех решений разработки не проводилась. Эти два ограничения касаются каждого приведённого ниже результата и далее отдельно не повторяются.

1 Связанные работы и выбор подходов

Рассматриваемая задача объединяет три вопроса: как построить управляющий закон, как соблюсти ограничения и как корректно сравнить результаты. Литература по каждому из них даёт свои основания для экспериментального протокола. Ниже обсуждается не общий рейтинг алгоритмов, а то, какие свойства подходов существенны именно для подъёма маятника на короткой направляющей.

1.1 Классическое управление как содержательная база сравнения

Линейно-квадратичный регулятор (Linear Quadratic Regulator, LQR) выбирает линейную обратную связь по отклонению от равновесия, а его коэффициенты определяются из квадратичного штрафа за отклонение состояния и за усилие управления. Для нелинейного маятника такой регулятор применяют к линеаризации около верхнего положения: он решает задачу локальной стабилизации и сам по себе подъёма снизу не задаёт. Дополняет его траекторная оптимизация — сначала строится номинальное движение, затем регулятор компенсирует отклонения от него. Оба метода изложены Р. Тедрейком [10, 11].

Разделение подъёма и стабилизации вытекает из нелинейности задачи. Линеаризация описывает малые отклонения от выбранного движения, и её точность не распространяется автоматически на нижнее положение маятника, поэтому траекторный регулятор использует изменяющееся во времени опорное движение, а стационарный LQR предназначен для локальной стабилизации около верхнего равновесия. В реализованном здесь контроллере переключение на него выполняется по окончании запланированной траектории, то есть по времени, а не по проверке близости состояния к равновесию. Сопоставлять такой подход с обучаемой политикой нужно по полной задаче подъёма и удержания, сохраняя при этом сведения о том, как построена опорная траектория.

В проекте классическая процедура включает заранее сохранённую траекторию подъёма, слежение с обратной связью и переход к LQR. Она нужна не только как техническая проверка симулятора: если известная модель уже допускает эффективное классическое решение, успех обучаемого метода следует сопоставлять именно с ним, а не только с бездействием. Одна фиксированная траектория, впрочем, не обязана подходить всем расширенным стартам, и это учитывается при интерпретации результатов Главы 5.

Исходный лабораторный проект `robotics-laboratory/cart-pole` предоставляет модель и основу классического управления [8]. Его вход — ускорение тележки, а не сила двигателя, и уже поэтому совпадение названия `CartPole` с другими средами не делает результаты сопоставимыми: проверять нужно уравнения, начальную область, длину направляющей и критерий успеха. Настоящая работа сохраняет лабораторную динамику и строит вокруг неё общий экспериментальный протокол.

1.2 Четыре подхода к обучению управляющего закона

Все рассматриваемые методы опираются на нейросетевую оценку ценности действия — ожидаемой будущей суммы наград при его выборе и последующем поведении. Такая оценка

позволяет учитывать отложенный результат: кратковременное движение тележки от центра может оказаться полезным, если впоследствии оно позволяет поднять маятник. Ценность не равна немедленной награде и сама является приближением, которое меняется по ходу обучения.

DQN (Deep Q-Network) обучает оценки для дискретного набора действий. Повторное использование переходов из буфера опыта и медленно меняющаяся целевая сеть снижают зависимость обучения от последовательности соседних наблюдений [6]. В нашей задаче DQN выбирает один из девяти запросов ускорения — это простой дискретный подход, но набор доступных ему запросов заведомо уже, чем у непрерывных методов. Общая физическая среда, как видно уже здесь, не означает одинакового класса возможных управляющих законов.

DDPG (Deep Deterministic Policy Gradient) предназначен для непрерывных действий. Сеть управления, *актор* (actor), выдаёт действие, а сеть оценки, *критик* (critic), предсказывает его ценность; актер меняется в направлении роста предсказанной ценности, а исследование обеспечивается добавленным шумом [5]. DDPG выбран как базовый непрерывный метод. Его зависимость от качества критика делает особенно полезной проверку разных seed, хотя сама по себе архитектура ещё не объясняет неуспех конкретного обучения.

SAC (Soft Actor-Critic) сочетает рост ожидаемого возврата с энтропией — мерой разнообразия распределения действий. Стохастическая политика поддерживает исследование, а две оценки критиков используются для более осторожной цели обновления [1]; вариант с автоматической настройкой веса энтропии описан в развитии метода [2]. Для маятника SAC интересен как способ находить последовательность подъёма без заранее заданной траектории. Энтропия при этом остаётся свойством распределения действий и ограничением на положение тележки не является, так что заменить защиту она не может.

TQC (Truncated Quantile Critics) сохраняет энтропийного актора, но критики предсказывают квантили распределения возврата вместо одного среднего, и при построении обучающей цели часть наиболее высоких прогнозов отбрасывается [4]. Это механизм контроля переоценивания, а не встроенная проверка физических границ. Сопоставление SAC и TQC показывает результат двух полных процедур; без отдельного эксперимента с выключенным усечением оно не устанавливает, что возможное преимущество вызвано именно квантилями.

Четыре метода вместе покрывают несколько разных способов построения политики: дискретный выбор запросов, детерминированное непрерывное управление, стохастическое управление с энтропийным критерием и его развитие с распределительной оценкой возврата. Исчерпывающим обзором современных алгоритмов такой набор, конечно, не является — он выбран для содержательного сравнения при доступном бюджете. Добавление новых методов без сопоставимого подбора параметров само по себе не сделало бы выводы сильнее.

Различия алгоритмов не следует путать с доказанными причинами экспериментальных исходов, и дальше это правило применяется последовательно. Успешность TQC не доказывает пользу усечения квантилей, пока нет сравнения с отключённым усечением. Неудача DQN не устанавливает, что девяти действий недостаточно: одновременно влияют обучение оценки ценности, исследование среды и бюджет переходов. Поэтому результаты интерпретируются на уровне полных процедур; об отдельных механизмах эти данные не говорят.

Использованы реализации Stable-Baselines3 и SB3-Contrib [7, 9]: библиотечные алгоритмы не переписывались и авторскими здесь не выдаются, а разработанная часть проекта описана в Главе 3. Общие небольшие сети и одинаковый бюджет взаимодействий делают сравнение обозримым, но индивидуально оптимальных настроек каждому методу не гарантируют. Выводить из полученного порядка результатов общий рейтинг алгоритмов на всех задачах управления было бы ошибкой.

1.3 Защитный фильтр и достоверность сравнения

Предиктивные защитные фильтры отделяют предложение контроллера от проверки его допустимости. У Wabersich и Zeilinger фильтр использует прогноз ограниченной нелинейной системы и при необходимости корректирует вход [12]. В нашем случае реализована существенно более узкая процедура — аналитический прогноз координаты и скорости тележки при постоянном ускорении. Воспроизведением общего нелинейного алгоритма из этой статьи она не является и гарантий для неопределённой динамики автоматически не наследует.

Safe-control-gym объединяет оценку качества и безопасности классических и обучаемых регуляторов, в том числе при возмущениях [13]. Для настоящей работы важен отсюда принцип раздельных метрик: агент может достичь цели, нарушив ограничение, либо сохранить ограничение, не достигнув цели. Шумы, задержки и ошибки параметров в нашем протоколе не испытывались, поэтому численные результаты здесь с этим набором задач напрямую не сопоставляются — он служит методологическим ориентиром.

Henderson и соавторы показывают, насколько выводы о глубоком обучении с подкреплением зависят от случайности и деталей процедуры [3]. Отсюда прямо следуют три решения протокола: сохранять каждый запуск, оценивать последние веса отдельно от лучших и проверять выбранную настройку на новых seed. Три значения seed не дают точной оценки распределения качества будущих обучений, но позволяют увидеть крупную неоднородность, которую единственный успешный пример скрыл бы полностью.

1.4 Позиционирование настоящего исследования

Из рассмотренных работ следуют три требования к сравнению: определить модель и критерии явно, поскольку одинаковое название задачи не гарантирует одинаковой динамики; измерять соблюдение ограничений отдельным механизмом и отдельными показателями, поскольку высокая награда сертификатом безопасности не является; и не считать результат единственного обучения оценкой повторяемости процедуры.

Настоящий проект реализует эти требования в лабораторной модели с ускорительным входом. Его результат — не универсальное преимущество обучения с подкреплением над классическим управлением, а воспроизводимое сопоставление конкретных процедур вместе с диагностикой их ограничений. Общая модель делает физические результаты сравнимыми, а разделение отбора, новых запусков и новых стартов позволяет каждый раз сказать, на какие именно данные опирается вывод. В следующей главе эти принципы переводятся в уравнения и измеряемые критерии.

2 Модель, защитный фильтр и критерии качества

2.1 От установки к расчётной модели

Тележка перемещает шарнир маятника вдоль горизонтальной направляющей. Движение шарнира меняет угол маятника, хотя отдельного привода на его оси в расчётной модели нет. Рисунок 1 показывает лабораторную установку из предоставленной видеозаписи, а Рисунок 2 помогает различить основные узлы. Оба изображения объясняют устройство стенда и не свидетельствуют об испытании наших обученных политик на нём.




Рисунок 1 – Лабораторная установка.




Рисунок 2 – Основные узлы установки.
Схематическое изображение.

Состояние обозначим $s = (x, v, \theta, \omega)$. Здесь x — горизонтальная координата шарнира в метрах, $v = \dot{x}$ — скорость тележки в м/с, θ — угол в радианах от вертикали вниз, $\omega = \dot{\theta}$ — угловая скорость в рад/с. Положительное направление x — вправо, и при небольшом положительном θ конец маятника смещён вправо от нижней вертикали. Нижнему равновесию соответствует $\theta = 0$, верхнему — $\theta = \pi$ с точностью до полного оборота 2π .

Рисунок 3 закрепляет геометрические соглашения. В классическом регуляторе используется другой порядок компонент, $q = (x, \theta, v, \omega)$, — это перестановка того же физического состояния, а не иная модель.

2.2 Уравнения и постоянное управление между отсчётами

Контроллер задаёт ускорение тележки u в м/с². Приняты уравнения

$$\dot{x} = v, \quad \dot{v} = u, \quad \dot{\theta} = \omega, \quad \dot{\omega} = -\frac{u \cos \theta + g \sin \theta}{l}. \quad (1)$$

Положение конца идеализированного маятника относительно шарнира равно $(l \sin \theta, -l \cos \theta)$, а проекция ускорения на касательную даёт $l\ddot{\theta} + u \cos \theta = -g \sin \theta$, что согласуется с последним уравнением (1). Около верха, положив $\varphi = \theta - \pi$, получаем $\ddot{\varphi} \approx (g/l)\varphi + u/l$: малое отклонение нарастает экспоненциально, и без подходящей обратной связи маятник падает.

Управляемое ускорение — свойство лабораторной модели, унаследованное вместе с ней, и оно заметно упрощает постановку. Реакция маятника не изменяет предписанное ускорение тележки, а масса в уравнения вообще не входит. Не описаны и трение, инерция и насыщение




Рисунок 3 – Соглашения расчётной модели: угол от нижней вертикали, вход $u = \ddot{x}$, длина $l = 0,18$ м. Пунктир — желаемые границы положения шарнира $\pm 0,24$ м.

привода по силе, люфт, шум измерений и задержки. Отсюда следует практический вывод: найденное управление нельзя перенести на установку одним пересчётом единиц — понадобится отдельно проверить и исполнение ускорения, и адекватность самой динамики.

Параметры приведены в Таблице 1. Длина и рабочие пределы восходят к лабораторной конфигурации и в экспериментальном контракте заданы явно вместе с g и аварийными пределами. Это настройки симуляции, а не результаты идентификации оборудования. Копии контракта и конфигураций перечислены в Приложении В.

Таблица 1 – Параметры модели и уровни ограничений

Величина	Значение	Смысл
g, l	9,8 м/с ² ; 0,18 м	Ускорение тяжести и длина маятника
$\Delta t, T$	0,01 с; 10 с	Интервал управления и горизонт эпизода
A	4 м/с ²	Максимум приложенного $ u $ при обоих режимах
X, V	0,25 м; 2 м/с	Границы прекращения эпизода по x, v
L_{desired}	0,24 м	Желаемая граница защиты по положению
Аварийный $ x $	0,27 м	Дополнительный предел исходного симулятора
Аварийные $ v , u $	2,5 м/с; 5 м/с ²	Внутренняя аварийная политика
Интегратор	Адаптивный RK3	Точность 10^{-6} , шаг не более 0,01 с; фиксированный шаг выключен

Между моментами управления команда постоянна, поэтому за интервал длины h движение тележки известно аналитически:

$$x(\tau) = x_0 + v_0\tau + \frac{1}{2}u\tau^2, \quad v(\tau) = v_0 + u\tau, \quad 0 \leq \tau \leq h. \quad (2)$$

Формулы (2) позволяют проверить весь интервал целиком, включая внутренний экстремум x , а не только конечный отсчёт. Общий исполнитель команд находит первое предстоящее нарушение $|x| \leq X$ или $|v| \leq V$ и останавливает переход ровно на границе, причём касание с возвращением внутрь выходом не считается. Состояние маятника до фактического момента остановки вычисляет исходный Drake — упрощённый аналитический интегратор тележки его не подменяет.

Событие достижения границы положения означает, что эпизод остановлен перед выходом за $\pm 0,25$ м. Численного превышения этого предела оно не подразумевает и отличается от превышения желаемых $\pm 0,24$ м, о котором речь пойдёт ниже. Переход при этом может оказаться укороченным или нулевым, если из граничного состояния движение направлено наружу. После терминального события следующее исполнение запрещено до нового сброса среды, а ошибки симулятора и исключения интегратора в успешное завершение не превращаются.

2.3 Наблюдение, запрос и фактически приложенное ускорение

Агенту передаётся не внутренний вектор Drake, а наблюдение

$$o(s) = \left(x/0,25, v/2, \sin \theta, \cos \theta, \omega/\sqrt{g/l} \right). \quad (3)$$

Все величины в (3) безразмерны: каждая координата поделена на свой характерный масштаб. Синус и косинус представляют угол без разрыва на границе полного оборота — две записи угла, отличающиеся на 2π , описывают одну конфигурацию и дают одинаковое наблюдение. Само наблюдение округляется до float32, тогда как физический журнал хранит полный угол и исходные компоненты состояния. Классический регулятор наблюдения не использует и получает состояние непосредственно.

SAC, TQC и DDPG формируют нормированный запрос $a \in [-1, 1]$, которому соответствует $u_{\text{req}} = 4a$. Для DDPG при обучении сначала добавляется исследовательский шум, а затем запрос ограничивается указанным диапазоном. DQN выбирает индекс одного из девяти ускорений $\{-4, -3, \dots, 3, 4\}$ м/с² — равномерная сетка с шагом 1 м/с² по всему допустимому диапазону, включающая нуль. После фильтра исполняемая команда DQN может оказаться и между узлами этой сетки. Классическая обратная связь выдаёт физический запрос u_{req} , который до общего исполнительного слоя может превышать ± 4 .

Дальше запрос проходит через один из двух режимов. В режиме *off* исполнитель просто ограничивает амплитуду: $u_{\text{cmd}} = \min(A, \max(-A, u_{\text{req}}))$. В режиме *on* фильтр получает **исходный физический запрос**, а ограничение амплитуды входит в вычисляемое им множество допустимых команд. Величина вмешательства измеряется относительно исходного запроса и поэтому включает в себя и коррекцию амплитуды, если запрос выходил за пределы допустимых ускорений. Рисунок 4 показывает весь путь команды.

Точность здесь важна в обе стороны. Фильтр читает исходные x, v полной точности, а не восстанавливает их из округлённого наблюдения; выбранное ускорение передаётся в Drake непосредственно, без повторной нормализации и обратного преобразования в float32. *Приложенным ускорением* называется команда последнего реально выполненного перехода.

Replay: запрос а; журнал: запрос, команда, фактически исполненное и




Рисунок 4 – Путь команды и обратной связи. On — фильтр с ограничением амплитуды; off — обычный ограничитель. Оба режима сохраняют события рабочих границ. В буфер опыта поступает запрос агента, а в журнал — запрос, выбранная команда и фактическое исполнение.

Если время не продвинулось, приложенной команды нет: она считается отсутствующей, а не равной нулю, и эта оговорка существенна для отказа, случившегося до начала движения.

Буфер опыта (replay buffer) — хранилище прошлых переходов, из которого обучение многократно берёт примеры, — сохраняет наблюдение, **запрошенное** действие, награду, следующее наблюдение и признак окончания. В режиме on агент тем самым учится выбирать запросы к среде, которая уже включает защитное преобразование $F(s, u_{\text{req}})$. Замена запроса исполненным ускорением изменила бы решаемую задачу, поэтому она не производится. Энтропия SAC и TQC тоже относится к запросам, а не к командам: несколько разных запросов могут после защиты дать одну и ту же команду.

2.4 Почему одной проверки положения недостаточно

Проверять текущую координату тележки мало, и это видно на числовом примере. Пусть тележка ещё внутри направляющей, но быстро движется к краю. При максимальном торможении A тормозной путь равен $v^2/(2A)$, так что из $x = 0,23$ м при $v = 0,5$ м/с для остановки вправо нужно $0,03125$ м, а точка остановки $0,26125$ м лежит уже за желаемой границей. Такой старт простым ограничением текущего ускорения не исправить: тормозить нужно было раньше.

Поэтому в фильтре используются внутренние пределы $L = 0,24 - 10^{-6}$ м и $W = 2 - 10^{-6}$ м/с, а допустимая область координаты и скорости определяется с учётом тормозного пути. Обозначим $[z]_+ = \max(z, 0)$; тогда

$$K = \left\{ (x, v) : |x| \leq L, |v| \leq W, x + \frac{[v]_+^2}{2A} \leq L, -x + \frac{[-v]_+^2}{2A} \leq L \right\}. \quad (4)$$

Два последних условия (4) и требуют места для торможения в сторону движения. Проверка K намеренно не учитывает угол маятника: она отвечает только за тележку, и из принадлежности K возможность успешного подъёма маятника за 10 с никак не следует.

При обучении с фильтром сброс допускает только состояния из K — без повторного случайного подбора и без изменения координат; при off проверяется рабочий прямоугольник

$|x| \leq 0,25$, $|v| \leq 2$. Весь использованный малый обучающий диапазон целиком лежит в K , поэтому состав обучающих стартов от этой проверки не меняется. Для произвольных стартов различие уже существенно, и в Главе 5 оно отдельно оговаривается. Исполнитель классики проверяет ограничения сброса, а затем допустимость команды.

2.5 Как фильтр выбирает команду

Пусть до следующего момента управления осталось $h \leq 0,01$ с. Фильтр рассматривает постоянные ускорения и строит множество

$$\mathcal{U}_h(x_0, v_0) = \{u \in [-A, A] : |x(\tau)| \leq L, |v(\tau)| \leq W \quad \forall \tau \in [0, h], \\ (x(h), v(h)) \in K\}. \quad (5)$$

В (5) первая проверка защищает ближайший интервал, а последняя сохраняет возможность торможения после него. Для координаты проверяются начало, конец и вершина параболы $\tau_* = -v_0/u$, если $u \neq 0$ и $0 < \tau_* < h$; скорость линейна, поэтому её абсолютный максимум достигается на одном из концов.

В реализации допустимые ускорения образуют интервал, границы которого получаются из аналитических ограничений скорости, положения и конечного тормозного пути, причём левое ограничение вычисляется симметричным отражением x, v, u . Это одномерная аналитическая процедура, без запуска общего оптимизационного решателя. В идеальной арифметике выбирается ближайший к запросу элемент интервала:

$$u_{\text{proj}} = \min(u_{\text{max}}, \max(u_{\text{min}}, u_{\text{req}})), \quad [u_{\text{min}}, u_{\text{max}}] = \mathcal{U}_h(x_0, v_0). \quad (6)$$

Формула (6) сохраняет уже допустимую команду без изменений, а запрос, из-за которого тележка потеряла бы тормозной запас, сдвигает к ближайшей допустимой границе. Отсюда видна и роль фильтра, и её предел: он не задаёт собственной траектории подъёма и не оптимизирует награду, а лишь минимально корректирует текущий запрос в рамках проверяемых ограничений.

Численная реализация слегка отличается от этой идеальной проекции, и знать об этом нужно при чтении журналов: исполняемая команда может немного не совпадать с точной математической проекцией. Причина в том, как вычисляются границы интервала — исходные двоичные числа проверяются точной рациональной арифметикой, корни находятся с повышенной десятичной точностью, концы округляются внутрь и проверяются повторно, а при коррекции на геометрической или скоростной границе допускается дополнительный сдвиг внутрь не более 10^{-8} м/с², ограниченный шириной интервала. Допуск при этом касается только команды: координаты состояния ради него не округляются и не подрезаются.

Два исхода работы фильтра различаются по смыслу. *Вмешательство* регистрируется, когда принятая фильтром команда отличается от исходного запроса, и его величина равна $|u_{\text{filtered}} - u_{\text{req}}|$; для классики сюда входит и ограничение большой амплитуды. *Отказ* — случай иного рода: состояние недопустимо либо не удалось подтвердить представимую численную команду. Тогда эпизод завершается ещё до движения, с нулевой длительностью и отсутствующей приложенной

командой. Нулевым управлением отказ не маскируется — иначе он выглядел бы в журнале как обычный шаг.

Для идеальной модели существование допустимой команды можно обосновать; ниже приведена схема такого рассуждения, а не его полное изложение. При условиях $Ah \leq W$ и $Ah^2 \leq 2L$ из любого $(x, v) \in K$ подходящее постоянное ускорение существует. При достаточно большой скорости годится полное торможение; при малой — остановка к концу шага, если до края хватает пути, либо разворот с полным торможением, а случай движения влево симметричен. Ключевой шаг в том, что конец интервала снова оказывается в K , и рассуждение можно повторять шаг за шагом. Проверка всех промежуточных оценок здесь не приводится; параметры фильтра, используемые при этом соглашения и ссылка на реализацию собраны в электронном приложении «Фильтр тележки».

Область действия этого аргумента стоит очертить точно. Он требует точной модели, исходных состояний без ошибок, неизменных пределов и исполнения команды на заданное время без задержек. Он не доказывает ни удержания маятника, ни общей безопасности численного Drake, ни работоспособности реального привода, а внутренний запас 10^{-6} м остаётся параметром протокола, а не измеренной границей ошибки оборудования. Эксперимент дальше проверяет конечный набор исполнений и математический аргумент не заменяет.

2.6 Награда и физический критерий успеха

Награда R1 плавно поощряет верхнее положение и малые отклонения. Обозначим $q(z) = (1 + z^2)^{-1}$ и $H(\theta) = (1 - \cos \theta)/2$; на конце перехода фактической длительности h_k вычисляется

$$r_k = \frac{h_k}{\Delta t} H(\theta_{k+1}) q\left(\frac{x_{k+1}}{0,25}\right) q\left(\frac{v_{k+1}}{2}\right) q\left(\frac{\omega_{k+1}}{2}\right) q\left(\frac{u_{\text{applied},k}}{40}\right) - 5d_k. \quad (7)$$

Структура (7) мультипликативна, и это определяет её поведение: множитель H отвечает за высоту маятника, каждый $q(\cdot)$ штрафует одно отклонение, а произведение велико лишь тогда, когда все сомножители хороши одновременно. Каждый множитель $q(\cdot)$ не превосходит единицы и при конечном аргументе остаётся положительным. Поэтому большое нормированное отклонение по одной координате уменьшает положительную часть награды, а остальные множители, также не превосходящие единицы, компенсировать это уменьшение не могут. Обратиться в нуль вся положительная часть тем не менее может: для этого достаточно $H(\theta_{k+1}) = 0$, то есть точного нижнего положения, либо $h_k = 0$. Здесь $d_k = 1$ при терминальном завершении по рабочему ограничению или отказу фильтра, а масштабы имеют единицы соответствующих физических величин. Угловая скорость в награде нормируется на 2 рад/с, тогда как в наблюдении — на $\sqrt{g/l}$: у этих величин разные роли. Масштаб 40 м/с² эквивалентен коэффициенту 0,1 перед нормированным ускорением. Положительная часть на полном шаге лежит в $[0, 1]$, постоянного бонуса за выживание нет, а при нулевом переходе она равна нулю, тогда как штраф остаётся -5 .

Отчётный *возврат* (return) — недисконтированная сумма $G = \sum_k r_k$. При обучении будущие награды умножаются на степени коэффициента $\gamma = \exp(-0,01/5) \approx 0,998002$. Достижение горизонта трактуется как временное усечение: при обновлении ценности учитывается возможность продолжения из конечного наблюдения, тогда как физический отказ

такое продолжение прекращает. Это различие сохраняется в буфере опыта и ради результатов не менялось.

Критерий задачи задаётся отдельно от награды и по другим правилам. Пусть $e_\theta = \text{atan2}(\sin(\theta - \pi), \cos(\theta - \pi))$ — периодическая ошибка относительно верха. Область удержания определяется четырьмя одновременными условиями:

$$|e_\theta| \leq 10^\circ, \quad |\omega| \leq 0,5 \text{ рад/с}, \quad |x| \leq 0,20 \text{ м}, \quad |v| \leq 0,20 \text{ м/с}. \quad (8)$$

Успехом считается полный горизонт 10 с без терминального отказа и заключительный непрерывный по записанным отсчётам интервал $H_f \geq 2$ с в области (8); самый длинный такой интервал за весь эпизод обозначим H_ℓ . Раздельные посещения области не суммируются: стоит тележке выйти за скоростной порог, как интервал удержания прерывается и отсчёт начинается заново. Допуск времени равен 10^{-12} с. Отметим, что проверка одного лишь угла означала бы просто посещение верха и была бы существенно слабее; соблюдение угловых условий между отсчётами при этом не доказано.

Заметим заранее, что награда и успех могут расходиться, и никакой ошибки расчёта в этом нет. Небольшое превышение жёсткого порога скорости разрушает двухсекундное удержание, но почти не меняет плавный множитель награды. К тому же возврат суммируется по всей траектории, а успех зависит только от её конца. Поэтому выбор модели ниже опирается на удержание, а возврат используется как дополнительная диагностическая величина; Глава 4 показывает измеренный случай такого расхождения.

2.7 Как измеряется безопасность

Для положения используется интервальный максимум $M_x = \max_t |x(t)|$, включающий аналитический экстремум между командами. Строгое превышение означает $M_x > 0,24$ м, а превышение с учётом численного допуска (*resolved*) — $M_x > 0,24 + 10^{-12}$ м. Этот допуск относится к анализу: он не переносит границу события с 0,25 м и не заменяет внутренний запас фильтра 10^{-6} м. При расчёте дополнительно учитываются аналитическое конечное положение тележки и численно устойчивое суммирование, а версия расчёта зафиксирована в электронных материалах.

Успех без превышения с допуском — пересечение двух критериев, и он не переопределяет исходный успех удержания. Отсутствие всех возможных опасностей он тоже не означает: измеряется ровно то, что перечислено.

Доля вмешательств в режиме оп — это число изменённых принятых решений, делённое на число всех принятых решений; при агрегировании суммируются оба счётчика, а среднее процентов по эпизодам не применяется. При выключенном фильтре доля вмешательств не определена, и это не то же самое, что ноль: отсутствие защитного слоя отличается от его работы без коррекций. Отказы считаются отдельно.

Такой набор метрик и позволяет различать три существенно разные ситуации: успех с нарушением желаемой границы, остановку у края без решения задачи и допустимое движение без удержания. Именно эти различия понадобятся в Главах 4 и 5. Постановка, таким образом,

разделяет запрос контроллера, исполняемую команду и физический исход эпизода; фильтр ограничивает движение тележки на основе модели, награда направляет обучение, а критерий удержания определяет успех.

3 Обучение и правила сравнительного исследования

3.1 Обновление моделей и классическая обратная связь

Обучение чередует два действия: сбор переходов среды и обновление нейросетей по накопленному опыту. Поскольку сохранённые переходы используются многократно, в том числе собранные прежними версиями политики, методы называют *off-policy*. Критик приближает дисконтированную ценность запроса, актор (если он есть) формирует запрос по наблюдению, а целевая сеть — медленно меняющаяся копия, от которой отсчитываются ориентиры обучения.

Обновление критика опирается на разложение будущего результата: награда ближайшего перехода плюс оценка того, что достижимо после него. Истинный будущий возврат неизвестен, поэтому второе слагаемое берётся от целевой сети, и критик уменьшает расхождение собственного прогноза с такой составной целью. В непрерывных методах актор затем выбирает действия с высокой оценкой критика, так что ошибка оценки распространяется и на политику. Высокий прогноз критика остаётся прогнозом: измеренным качеством управления он не является.

Ниже o, a, r, o' обозначают наблюдение, запрос, награду и следующее наблюдение; $d = 1$ означает терминальное событие, после которого будущий возврат не учитывается. Временное усечение по горизонту таким событием не считается. Через Q_ψ обозначен критик с параметрами ψ , через μ_η или π_η — актор с параметрами η , черта над параметрами указывает на целевую сеть, а y — целевое значение для обновления критика.

Для DQN цель имеет вид $y = r + \gamma(1 - d) \max_{a'} Q_{\bar{\psi}}(o', a')$: сеть приближает её по сохранённым переходам, а при оценке выбирается индекс максимальной ценности. В обучении применяется ε -жадное исследование, где вероятность случайного запроса линейно уменьшается от 1 до 0,05 за первые 20% бюджета, а целевая сеть обновляется каждые 1000 переходов. Используется обычный DQN из библиотеки, без дополнительных расширений, которые иногда публикуются под тем же именем.

DDPG использует цель $y = r + \gamma(1 - d) Q_{\bar{\psi}}(o', \mu_{\bar{\eta}}(o'))$ с детерминированным актором μ_η , обновление которого направлено на увеличение $Q_\psi(o, \mu_\eta(o))$. В нашей конфигурации критик один, а исследование обеспечивается независимым гауссовым шумом со стандартным отклонением $\sigma = 0,1$ в нормированных запросах. При внешней оценке шум отключается, поэтому разнообразие опыта, полезное при обучении, не переносится на измеряемое поведение.

SAC оптимизирует не только возврат, но и энтропию запросов. Для выбранного следующего запроса $a' \sim \pi_\eta(\cdot|o')$ цель двух критиков записывается как

$$y = r + \gamma(1 - d) \left[\min_{j=1,2} Q_{\bar{\psi}_j}(o', a') - \alpha \log \pi_\eta(a'|o') \right]. \quad (9)$$

Актор минимизирует среднее $\alpha \log \pi_\eta(a|o) - \min_j Q_{\psi_j}(o, a)$, а коэффициент α в (9) настраивается автоматически с начальным значением 0,1. Внешняя оценка использует детерминированный режим библиотечной политики и нового случайного выбора действий не делает: случайность обучения и случайность исполнения в работе не смешиваются.

TQC сохраняет энтропийного актора, но каждый критик предсказывает не одно число, а 25 квантилей распределения возврата. В исследованной конфигурации критиков два, параметр удаления верхних квантилей равен двум на сеть, и из объединённых 50 прогнозов в цель попадают 46 нижних; обучение критиков ведётся квантильной регрессией. Квантили описывают возможные уровни возврата, а не отдельные рассчитанные вперёд траектории, и усечение верхней части делает цель осторожнее по отношению к завышенным оценкам. Механизм направлен против переоценивания, а не против нарушения физических границ: ни критик, ни актор TQC не проверяют тормозной путь тележки — это по-прежнему делает общий фильтр.

Классический контроллер устроен иначе: он не обучается, а исполняет заранее рассчитанный план. Сначала он следует сохранённому решению прямой коллокации — метода траекторной оптимизации, который ищет состояния и входы сразу на всей временной сетке, связывая соседние узлы условиями динамики; результат даёт номинальные состояние $q_0(t)$ и ускорение $u_0(t)$. Отклонения от плана компенсирует TVLQR (Time-Varying Linear Quadratic Regulator) — линейно-квадратичный регулятор с зависящими от времени коэффициентами, задающий запрос

$$u_{\text{req}}(t) = u_0(t) - K(t)(q - q_0(t)) - k_0(t), \quad q = (x, \theta, v, \omega). \quad (10)$$

Аффинный член k_0 в (10) учитывает дефект восстановленной номинальной траектории. После конца плана однократно выполняется переход к стабилизирующему LQR: $u = -K_b(x, e_\theta, v, \omega)^T$, с матрицей штрафа за состояние $Q = \text{diag}(10, 1, 10, 1)$ и штрафом за управление $R = 0,5$. Ошибка угла периодическая только в режиме балансировки, тогда как слежение сохраняет запланированный полный оборот. Повторного планирования и новой попытки подъёма после неудачного захвата в этой реализации нет, поэтому классика выступает конкретным baseline, а не оптимальным регулятором для каждого нового старта.

3.2 Общие условия и единицы сравнения

Исходное распределение сброса среды (*reset*) — произведение независимых равномерных распределений:

$$\begin{aligned} x_0 &\sim U[-0,02, 0,02] \text{ м}, & v_0 &\sim U[-0,02, 0,02] \text{ м/с}, \\ \theta_0 &\sim U[-0,05, 0,05] \text{ рад}, & \omega_0 &\sim U[-0,05, 0,05] \text{ рад/с}. \end{aligned} \quad (11)$$

Значение *seed* обучения задаёт поток случайности, но не границы (11); для обоих режимов фильтра весь этот малый прямоугольник допустим при сбросе. Во время движения агент, разумеется, попадает и в другие состояния — это не делает их исходными состояниями обучения.

Каждое обучение в анализируемых сериях содержит 100 000 переходов, одну среду, буфер на 100 000 записей и пакеты по 64 перехода (размер пакета, *batch size*). Сети имеют два скрытых слоя по 64 нейрона с ReLU, функцией $z \mapsto \max(0, z)$; параметры обновляет оптимизатор Adam по оценке градиента из пакета опыта. Базовая скорость обучения равна $3 \cdot 10^{-4}$. После 128 начальных переходов выполняется одно обновление на каждый переход, всего 99 872. У непрерывных методов коэффициент мягкого обновления целей равен 0,005, у DQN действуют указанные выше

периодические обновления. Физика, интегратор, награда R1 и семантика запросов у всех методов общие (Приложение В).

Одинаковый бюджет уравнивает процедуры по числу взаимодействий со средой — но не по вычислительному времени и не по достигнутой сходимости. У TQC дополнительные квантильные прогнозы меняют объём вычислений, так что равенство числа переходов не означает равенства стоимости обучения. Обучения запускались параллельно, поэтому сумма длительностей процессов не является временем всей серии. В 33 обучения Таблицы 2 входят только анализируемые серии, без системных диагностических пилотов и замеров производительности.

Таблица 2 – Состав анализируемых серий и назначение данных

Серия	Что сравнивается	Обучений	Оценочные старты
Основная	SAC/TQC/DDPG/DQN с фильтром; сопоставимый SAC без него, seed 0–2	15	20 валидационных + 3 именованных
Stage 1	Два изменения DDPG-on и SAC-off, seeds 0–2	12	Прежние 20 + 3
Confirmation	Фиксированные warmup5000, новые seeds 3–5	6	Прежние 20 + 3
Robustness	Шесть лучших исходных политик и классика, исполнение off/on	0	140 новых: 7 групп

3.3 Выбор контрольной точки и проверка настройки

Через каждые 10 000 обучающих переходов, включая исходную и конечную модели, проводится детерминированная оценка на 20 фиксированных validation-состояниях из (11). Ещё три именованных сценария (*named*) задают точное нижнее положение и $\theta_0 = \pm 0,02$ при остальных нулевых координатах; они описательные и в выбор не входят ни разу.

Лучшей точкой (*best*) называется сохранённая модель, максимизирующая лексикографический ключ — то есть сравнивается первая компонента, при её равенстве вторая и так далее:

$$K_{\text{ckpt}} = (p, \overline{H}_f, \overline{H}_\ell, -\bar{t}_{\text{first}}, n). \quad (12)$$

В (12) p — доля успеха на validation20, черта означает среднее, t_{first} — начало первого подтверждённого интервала удержания длиной не менее 2 с (среднее по эпизодам, где он есть), n — число обучающих переходов. Если такого интервала нет ни в одном эпизоде, вместо среднего времени подставляется 11 с, то есть значение заведомо хуже любого достижимого. При равных физических метриках выбирается более поздняя контрольная точка. Возврат в ключ не входит — по причинам, разобранным в конце Главы 2. Последней точкой (*last*) называются веса после 100 000 переходов; *best* и *last* относятся к одному обучению и независимыми повторениями эксперимента не являются.

Внешняя оценка сохранённых *best/last* выполняется при обоих режимах фильтра на тех же 23 стартах, что даёт $2 \times 2 \times 23 = 92$ слота на обучение; у классики их 46. Это проверка сохранённых моделей и влияния фильтра на их исполнение. Независимой оценкой обобщения она быть не может: validation уже использована при выборе.

Stage 1 меняет ровно одно значение относительно базовой настройки: либо начальный сбор опыта $128 \rightarrow 5000$ (`warmup5000`), либо скорость обучения $3 \cdot 10^{-4} \rightarrow 10^{-4}$ (`lr1e4`). Во втором случае остаётся 99 872 обновления, в первом — 95 000. Здесь важна тонкость, которая понадобится при интерпретации результатов: смена `warmup` затрагивает сразу и последовательность собираемого опыта, и число обновлений. Одна изменённая строка конфигурации не означает один изолированный причинный механизм, поэтому Stage 1 отвечает на вопрос «что лучше по правилу отбора», а не «почему это работает».

Настройка выбирается по трём seeds и только по валидации лучшей точки в режиме соответствующего обучения:

$$K_{\text{cfg}} = (\min_i p_i, \text{mean}_i p_i, \min_i \bar{H}_{f,i}, \text{mean}_i \bar{H}_{f,i}, \text{mean}_i \bar{H}_{\ell,i}). \quad (13)$$

По (13) требуется строгое улучшение исходной настройки, а при равенстве сохраняется базовый вариант. Для SAC-off используется оценка off: улучшение, которое даёт включение фильтра при оценке, в этот ключ не подставляется, иначе сравнивались бы разные системы.

Выбранные настройки затем без изменений проверяются на новых значениях seed 3, 4 и 5. Критерий confirmation закреплён до этой проверки и требует, чтобы каждый новый best имел $p \geq 0,8$, то есть не менее 16/20, чтобы не менее двух из трёх last также достигали $p \geq 0,8$ и чтобы все задания и оценки были завершены. Это правило принятия проекта, а не статистический тест с заданной вероятностью ошибки. Новые значения seed проверяют повторяемость обучения; старты оценки остаются прежними и независимыми от отбора не становятся.

3.4 Что проверяют данные и что разработано в проекте

Сравнение опирается на сохранённые конфигурации и контрольные точки, сводки обучения и журналы оценки, что позволяет связать каждый показатель с конкретным запуском и проверить, как применялись правила отбора. В электронном приложении представлены компактные таблицы, выбранные модели SAC/TQC и инструкции воспроизведения. Большие буферы опыта и полные архивы всех обучений в раздаточный комплект не входят.

Проверка сохранённых результатов и повторение эксперимента решают разные задачи. Пересчёт метрик по журналам устанавливает согласованность данных с определениями, но динамику заново не воспроизводит. Для повторного обучения нужны исходные настройки и программное окружение, причём даже при одинаковом seed численное поведение может зависеть от реализации. Полные временные ряды сохранены не для всех обучающих переходов, поэтому отсутствующие траектории по агрегатам не восстанавливаются.

Границу между собственной работой и заимствованным стоит провести явно. Из лабораторного проекта взяты сама модель динамики, её реализация в симуляторе и классическое управление — расчёт номинальной траектории прямой коллокацией, слежение TVLQR и стабилизирующий LQR; алгоритмы DQN, DDPG, SAC и TQC взяты из библиотек и не переписывались. В проекте построено то, что связывает эти части в один эксперимент: исправленный интерфейс симулятора; слой, превращающий достижение рабочих границ в корректно оформленные события эпизода; среда Gymnasium с наблюдением, наградой и

критерием удержания; защитный фильтр и его подключение к общему пути команд, одинаковому для обучаемых и классического контроллеров; журналы, разделяющие запрос, выбранную команду и фактическое исполнение; повторяемая процедура оценки и средства анализа. Вклад работы, таким образом, лежит в организации эксперимента и анализе его результатов, а создание физического симулятора или алгоритмов обучения в него не входит.

Итог протокола в том, что разные источники изменчивости получают разные знаменатели. Эпизод, уникальный физический старт, контрольная точка и независимый запуск обучения отвечают на разные вопросы, и смешивать их знаменатели нельзя. Следующие две главы используют эту структуру: Глава 4 разбирает изменчивость обучения, Глава 5 — изменчивость начальных условий.

4 Качество обучения и проверка повторяемости

4.1 Какие решения найдены в основной серии

Все 15 обучений основной серии завершены, каждое содержит 100 000 переходов и 99 872 обновления. В Таблице 3 режим оценки совпадает с режимом обучения, а значения относятся только к двадцати валидационным состояниям; SAC-off, в частности, не оценивается здесь с незаявленной дополнительной защитой.

Таблица 3 – Основная серия: успехи лучших / последних весов из 20

Конфигурация	Seed 0	Seed 1	Seed 2
SAC-on	20 / 20	20 / 20	20 / 20
TQC-on	20 / 20	20 / 20	20 / 20
DQN-on	20 / 11	14 / 14	20 / 20
DDPG-on	20 / 20	0 / 0	0 / 0
SAC-off	0 / 0	0 / 0	0 / 0
Классика	20/20 при off и on; без обучения		

Источник: Результаты вычислительных экспериментов автора; валидационные состояния, именованные исключены.

SAC-on и TQC-on находят успешные лучшие модели и сохраняют успех последних весов во всех трёх запусках. Метрика при этом насыщена — 20 из 20 у обоих методов и всех seeds, — поэтому безусловное превосходство одного над другим по этим данным установить нельзя. DQN и особенно DDPG заметнее зависят от seed: у DQN seed 0 последние веса дают 11 успехов против 20 у выбранных. Исходный SAC-off не решает задачу ни в одном запуске, и это результат конкретного бюджета и настроек, а не невозможность управления без фильтра.

Три именованных сценария рассматриваются отдельно и в отбор не входят. Для best SAC-on и TQC-on каждый seed даёт 3/3; DQN-on — 3/3, 2/3, 3/3; DDPG-on — 3/3, 0/3, 0/3; SAC-off — нули во всех трёх. Вместе с двадцатью валидационными состояниями это даёт описательные суммы 23/23 и 16/23, которые иногда удобнее для краткости, однако знаменателем выбора остаются именно 20 состояний.

Кривые на Рисунке 5 показывают, что одинаковый бюджет приводит к весьма разным траекториям качества. Каждая точка — оценка сохранённой модели; отрезок между точками лишь соединяет соседние измерения, и о качестве между ними ничего не известно. Потеря качества к концу обучения, хорошо заметная у DQN seed 0, и объясняет, зачем лучшие и последние веса хранятся раздельно.

4.2 Два разных сравнения фильтра

Фильтр участвует в эксперименте дважды — при обучении и при исполнении, — и эти два его вклада нужно различать. Строки Таблицы 3 сравнивают *процедуры целиком*: SAC-on и SAC-off имеют одинаковые базовые настройки и одинаковые seeds, но различаются и режимом обучения, и режимом оценки. Разрыв 20/20 против 0/20 на каждом seed относится именно к паре целых процедур.




Рисунок 5 – Успех на двадцати валидационных состояниях в основной серии. Фильтр при периодической оценке соответствует режиму обучения; каждый seed показан отдельно.

Чтобы отделить режим исполнения, достаточно уравнивать его. Сохранённые веса SAC-off, исполненные с фильтром, дают те же 0/20 на всех трёх seeds, то есть выдача защиты при оценке эту процедуру не спасает. В обратную сторону у SAC-on исполнение без фильтра снижает результат seed 1 с 20/20 до 0/20, тогда как seeds 0 и 2 сохраняют 20/20. Режим исполнения, следовательно, влияет на исход, но наблюдаемый разрыв между процедурами им не объясняется.

Остаётся вклад фильтра при обучении, и здесь данные позволяют меньше. Наличие защиты меняет не только правило исполнения, но и весь собранный опыт: длительности эпизодов, посещаемые состояния и дальнейшую последовательность случайных чисел. Эти механизмы в основной серии не разделялись, поэтому корректное утверждение звучит так: процедура обучения с фильтром в данном протоколе превосходит сопоставимую процедуру без него, а какая доля эффекта приходится на саму защиту, а какая на изменившийся опыт, из этих данных не следует. Универсальным свойством SAC результат тоже не является.

Второй способ исполняет *одни и те же веса* с фильтром и без него. У best SAC-on seed 1, TQC-on seeds 0 и 1, DDPG-on seed 0 и всех трёх DQN-on выключение защиты снижает validation-успех до нуля. У best SAC-on seeds 0 и 2, а также TQC-on seed 2 фильтр на этих стартах вообще не вмешивается, и оба режима дают 20/20. Полная матрица приведена в Приложении А. Зависимость

исполнения от защитного слоя отсюда видна прямо; при этом даже нулевая доля вмешательств при оценке не означает, что фильтр не повлиял на обучение, которое эти веса породило.

У классического контроллера соотношение иное. Оба режима успешны в 23/23 описательных сценариях, но при off в 21 из них превышаются желаемые 0,24 м, хотя события на 0,25 м не происходит. Один и тот же исходный успех, таким образом, допускает разные характеристики безопасности. На 713 внешних on-слотах основной серии аудит не нашёл ни превышений 0,24 м, ни событий положения, ни отказов фильтра — но эти слоты включают разные метки best/last и повторные старты, поэтому 713 независимых испытаний надёжности из них не получится.

4.3 Ограниченный подбор: победа по правилу и границы объяснения

Stage 1 содержит 12 новых обучений: DDPG-on и SAC-off, по два однофакторных кандидата и три значения seed. Таблица 4 даёт результаты best в режиме соответствующего обучения; базовый вариант взят из основной серии без повторного обучения.

Таблица 4 – Stage 1: успехи best из 20, seeds 0 / 1 / 2

Настройка	DDPG-on, оценка on	SAC-off, оценка off
Базовая настройка	20 / 0 / 0	0 / 0 / 0
Скорость обучения 10^{-4}	0 / 13 / 0	0 / 0 / 0
Начальный сбор 5000 переходов	0 / 20 / 20	20 / 0 / 0

Источник: Результаты вычислительных экспериментов автора; валидационные состояния, именованные исключены.

По правилу (13) строгим победителем в обеих группах оказывается вариант с начальным сбором 5000 переходов (warmup5000). Существенно, где именно достигается этот выигрыш: минимальный успех по seeds остаётся нулевым, и решает вторая компонента ключа — средняя доля, которая у DDPG растёт с 1/3 до 2/3, а у SAC-off с 0 до 1/3. Вариант 10^{-4} базовую настройку не улучшает. Точные ключи сохранены в электронных материалах, округлённые приведены в Приложении Б. Называть после этого DDPG или SAC-off устойчивыми к seed оснований нет.

За средними значениями скрывается заметный разброс. У DDPG warmup5000 seed 1 успех достигает 20/20 на 80 и 90 тыс. переходов, а затем падает до 0/20 на 100 тыс.; seed 2 после промежуточных провалов удерживает 20/20 на 80–100 тыс. У SAC-off весь выигрыш сосредоточен в seed 0, где best даёт 20/20, а last — 17/20 при off, тогда как seeds 1 и 2 двухсекундного удержания не приобретают вовсе. Одна улучшившаяся средняя величина, как видно, всю процедуру не описывает.

Гипотеза, стоявшая за увеличенным начальным сбором, предполагала улучшение раннего исследования верхней области. Проверка дала расщеплённый ответ: к 20 тыс. переходов доля таких образцов улучшилась у всех трёх запусков DDPG, но только у одного из трёх запусков SAC-off, тогда как заранее требовалось не менее двух. Следовательно, *победа SAC-off warmup5000 по итоговому ключу не подтверждает заявленный ранний механизм*. Для DDPG признаки гипотезу поддерживают, но не изолируют её: вместе с warmup меняются и данные, и случайная последовательность, и число обновлений. Переоценивание критика, недостаточная сеть или нехватка переходов как причины остаются недоказанными.

4.4 Подтверждение на новых значениях seed

Все шесть новых обучений warmup5000 и шесть внешних оценок завершены; каждое обучение содержит 100 000 переходов и 95 000 обновлений. При неизменных параметрах best DDPG-on на seeds 3/4/5 даёт 4/0/20 успехов из 20, а last — 0/0/0. SAC-off даёт нули и у лучших, и у последних весов во всех трёх случаях. Ни одна из конфигураций не проходит закреплённый критерий: не каждый best достигает 16/20, и нет двух успешных last.

Рисунок 6 сохраняет различие между seeds отбора и seeds проверки. Отрицательный результат получен в корректно завершённой серии и пропущенными заданиями не вызван. Правильность применения правила Stage 1 он не отменяет — он ограничивает практическую ценность выбранного улучшения. Дополнительный бюджет по итогам этой проверки автоматически не назначался.




Рисунок 6 – Warmup5000 на seeds 0–5: лучшие и последние веса на двадцати валидационных состояниях в режиме обучения. Вертикальная линия отделяет Stage 1 от confirmation; горизонтальный пунктир — порог 16/20.

4.5 Маятник сверху: почему это ещё не успех

Расхождение награды и успеха прямо зафиксировано в журналах last DDPG-on confirmation для seeds 3 и 5. Там все двадцать validation-эпизодов в последние две секунды удовлетворяют условиям на угол, угловую скорость и координату из (8) — маятник действительно стоит вверху. Прерывает удержание единственная оставшаяся компонента: скорость тележки выходит за 0,20 м/с. Из 4020 отсчётов последних двух секунд скорость допустима в 1925 (47,89%) для seed 3 и в 2404 (59,80%) для seed 5. Это доли отсчётов по двадцати траекториям, не доли успешных эпизодов; нарушение компоненты критерия зафиксировано здесь по журналам, а не по визуальному впечатлению от анимации.

Расхождение награды и успеха здесь тоже измеримо. Для seed 3 средний возврат от best к last растёт с 273,68 до 706,05, тогда как успех падает с 4/20 до 0/20, а среднее заключительное удержание — с 0,8895 до 0,3325 с. У seed 5 успех падает с 20/20 до 0/20, а удержание — с 7,8915 до 0,0115 с. Конкретная пара сохранённых траекторий seed 5 показана на Рисунке 7; в этом отдельном примере возврат, наоборот, снижается, и смешивать два наблюдения не следует.

Синхронное воспроизведение той же пары доступно в видеоприложении 2: последние веса визуально держат маятник около верха, но допустимой скорости тележки не обеспечивают.




Рисунок 7 – DDPG-on warmup5000, seed 5, validation_1000, оценка on: best 90k и last 100k. На заключительных двух секундах угол допустим, но last пересекает порог скорости. График построен по сохранённым состояниям двух эпизодов.

Такое расхождение прямо следует из определений. При $v = 0,30$ м/с множитель $q(v/2) \approx 0,978$ ещё почти не отличается от единицы, хотя жёсткий порог скорости удержания уже нарушен; к тому же возврат суммируется по всей траектории, а успех зависит только от её конца. Различие метрик этим объясняется, но причина изменения весов актора или критика — нет. У других неудачных запусков и траекторий механизмы могут быть иными, и отдельный ролик общего механизма ухудшения DDPG не доказывает.

Результат главы двойственен. В основной серии получены работающие SAC и TQC с фильтром, однако качество обучения воспроизводится не у всех методов одинаково, а настройка, выигравшая отбор на этапе разработки, проверку на новых запусках не прошла. Всё это говорит об изменчивости *обучения*. Следующая глава задаёт другой вопрос — насколько чувствительны уже обученные и закреплённые политики к начальному состоянию.

5 Структурированная проверка начальных условий

5.1 Что изменяется, а что остаётся фиксированным

Предыдущая глава меняла процедуру обучения и смотрела, что получится. Эта глава делает обратное: процедура остаётся позади, обучения не проводятся вовсе, а меняются начальные условия. Оцениваются шесть закреплённых лучших контрольных точек исходной основной серии — SAC-on и TQC-on с seed 0–2 — и прежний классический контроллер. Контрольные точки SAC выбраны на 70/50/80 тыс. переходах, TQC — на 80/40/70 тыс.; контрольные суммы весов и номинальной траектории закреплены до получения новых исходов (Приложение В).

Обозначение off/on здесь меняет смысл по сравнению с Главой 4. Раньше оно различало два способа обучения, теперь — только *режим исполнения одной и той же политики*, обученной с фильтром. SAC-off из предыдущей главы в матрицу не входит; DDPG и DQN тоже не включены, поскольку это ограниченная диагностика выбранных SAC/TQC и классики, а не повторное сравнение всех пяти методов. Их поведение при расширении стартов по этим данным оценить нельзя.

Семь групп содержат по 20 общих состояний, всего 140 уникальных стартов, и для каждого контроллера и режима используются те же точные координаты. Матрица имеет 7 контроллеров $\times$ 2 режима $\times$ 7 групп = 98 заданий по 20 эпизодов, то есть 1960 эпизодов и 980 полных пар.

5.2 Дизайн стартов и отношение к распределению обучения

Группы задаются правилами, а не случайным перебором, и перечислены в Таблице 5. Два масштаба задают размерность отклонений: $B = \sqrt{2AL} \approx 1,385638$ м/с — скорость, с которой тележка из центра успевает затормозить до желаемой границы, и $N = \sqrt{g/l} \approx 7,378648$ рад/с — естественный частотный масштаб маятника. Оба выведены из модели, а не из наблюдаемой области успеха: они задают шкалу возмущений, но не обещают, что внутри неё подъём удаётся.

Случайные значения создавались единственным PCG64 seed 2026091601: сначала 20 nominal-векторов, затем 10 joint-векторов, причём сетки случайный поток не расходуют. Все координаты записаны в SI, а угол отсчитывается от нижней вертикали и в исходных данных не оборачивается. Группа Joint включает зеркальные пары и растущий масштаб, поэтому независимой равномерной выборкой из большого прямоугольника она не является.

Все 140 стартов удовлетворяют (4). В Boundary условие $q < 1$ оставляет тормозной запас, а для Joint даже верхняя оценка $0,18 + 0,6^2/(2A) = 0,225 < L$ гарантирует выполнение позиционных условий отбора. Состояния не отбрасывались по результатам контроллера и не подрезались по координатам. У такого отбора есть и обратная сторона: старты, допустимые для off-reset по рабочему прямоугольнику, но отвергаемые on-reset, в сравнение не попали, и область сравнения этим сужена.

Полезно понять, насколько далеко эти старты уходят от того, на чём модели учились. Носитель (support) распределения (11) — совместный четырёхмерный прямоугольник, то есть множество совместно допустимых значений четырёх координат. Две Position-точки $x = \pm 0,02$ при остальных нулевых координатах лежат на границе его замыкания, хотя детерминированная

Таблица 5 – Точные правила семи групп, по 20 состояний

Группа	Значения и генерация	Отношение к области обучающих стартов
Nominal	Независимые $x, v \in [-0,02, 0,02]$, $\theta, \omega \in [-0,05, 0,05]$, равномерно	То же распределение, новые 20 точек
Position	$x = \pm\{0,02; 0,04; 0,06; 0,08; 0,10; 0,12; 0,15; 0,18; 0,21; 0,23\}$ м	Смешанная: 2 точки на границе носителя, 18 вне по одной оси
Velocity	$v = \pm 0,95B k/10$, $k = 1, \dots, 10$; максимум 1,316356 м/с	Одноосевое внераспределительное отклонение
Angle	$\theta = \pm k\pi/11$, $k = 1, \dots, 10$; максимум 2,855993 рад	Одноосевое отклонение; верх точно не включён
Angular velocity	$\omega = \pm Nk/10$, $k = 1, \dots, 10$	Одноосевое отклонение
Boundary	$x = \pm a$, $a \in \{0,20; 0,23\}$ м; $v = \text{sign}(x)q\sqrt{2A(L-a)}$, $q \in \{0,25; 0,5; 0,75; 0,9; 0,99\}$	Движение наружу у границы; вне прямоугольника по x, v
Joint	$s_k = (k/10) \text{diag}(0,18; 0,6; \pi; N)z_k$, $z_k \sim U([-1, 1]^4)$, и $-s_k$	Совместное отклонение по нескольким координатам

Источник: Зафиксированный дизайн экспериментов автора. В одноосевых группах остальные координаты нулевые; в Boundary $\theta = \omega = 0$. Точный список — в электронном приложении.

осевая пара и не имеет того же распределения, что обучающие старты. Остальные 18 Position, а также все Velocity, Angle и Angular velocity выходят за прямоугольник по одной оси; все Boundary — по двум. Среди Joint две точки выходят по двум координатам, десять — по трём, восемь — по всем четырём. Получается конкретная внераспределительная диагностика; глобальную устойчивость равновесия она не проверяет.

5.3 Сначала исходная задача: новые nominal-состояния

Прежде чем смотреть на отклонения, стоит убедиться, что политики решают исходную задачу на новых точках того же распределения. На nominal-стартах в режиме on SAC имеет 60/60 успешных исполнений, TQC — 59/60, классика — 20/20. Каждое RL-семейство использует здесь три политики на *одних и тех же двадцати состояниях*, так что речь не о 60 независимых физических стартах. Один nominal-эпизод TQC seed 1 неуспешен, и все 140 исполнений семи контроллеров дают 139 успехов.

Прежние 60/60 TQC на валидации и новые 59/60 на nominal друг другу не противоречат: validation использовалась для выбора best, nominal20 — другой набор точек из того же распределения. Перенос на близкие старты, таким образом, состоялся, но успех на всех точках даже малого прямоугольника этим не гарантирован. Видеоприложение 1 показывает три выбранных контроллера на общем nominal_00 — это иллюстрация успешного движения, а не все двадцать стартов.

5.4 Где проявляются ограничения захвата

Рисунок 8 сохраняет все семь контроллеров и семь групп и отвечает на вопрос, одинаково ли меняется качество при разных видах отклонения. Число успешных on-эпизодов из 140 в каждой группе: Nominal 139, Position 122, Velocity 109, Angle 102, Angular velocity 111,

Boundary 97, Joint 116. Труднее всего при таком равновзвешенном дизайне оказывается Boundary, где тележка изначально движется к краю. Это свойство выбранных точек и политик, а не универсальный порядок трудности всех возможных возмущений.




Рисунок 8 – Полная матрица успеха фиксированных контроллеров: каждое число из 20 общих состояний группы. Off/on — исполнение одних весов.

Различия между политиками видны и по строкам матрицы. На всех 140 стартах SAC-on seeds 0/1/2 имеет 135/129/128 успехов, TQC-on — 127/93/99, классика — 85. Одинаковый полный успех на старом validation, следовательно, не устранил различий между значениями seed обучения: он их скрыл. По семействам успех off → on меняется так: SAC — 279/420 → 392/420, TQC — 101/420 → 319/420, классика — 61/140 → 85/140, где знаменатели соответствуют числу исполнений, а не числу независимых обучений. Среднее по TQC заметно ровнее, чем сами seeds, и заменять им неоднородность не следует; вероятностями успеха в реальном применении эти доли тоже не являются.

Включение защиты помогает не на каждом старте. У SAC seed 2 в группе Angular velocity успех даже уменьшается с 18/20 до 16/20, а у классики Boundary остаётся 10/20 в обоих режимах. Причина в том, что фильтр не создаёт нового механизма захвата: он меняет вход тележки, а вслед за ним меняется и движение маятника, иногда не в лучшую сторону. Классический план в этом наборе выполняется прежним, с однократным переключением и без перепланирования под каждый старт. Видеоприложение 5 показывает по одному выбранному старту семи групп для SAC seed 0, а видеоприложение 6 — все семь контроллеров на joint_00. Все эти примеры успешны; неоднородность полной серии видна из таблиц и Рисунка 8.

5.5 Парное вмешательство: безопасность и задача

В Таблице 6 четыре разных исхода оставлены отдельными — именно их различие и составляет главный результат главы. Суммарный успех увеличивается с 441/980 до 796/980, то есть с 45,00% до 81,22% (на 36,22 процентного пункта). Успех без превышения с допуском возрастает с 394/980 до 796/980, на 41,02 п.п. Разница между 441 и 394 — это 47 успешных off-эпизодов, в которых желаемая граница всё же превышалась.

Таблица 6 – Robustness: исходы по всей фиксированной матрице

Показатель	Off, из 980	On, из 980
Исходный успех задачи	441	796
Успех без превышения с допуском	394	796
Превышение с допуском $\pm 0,24$ м	585	0
Достижение горизонта	446	980
Горизонт без заключительного удержания	5	184
Событие position_limit на $\pm 0,25$ м	534	0
Событие velocity_limit	0	0

Источник: Результаты вычислительных экспериментов автора. Числа строгих превышений и превышений с допуском здесь совпадают; определения различаются.

Во всех 980 on-эпизодах достигнут горизонт, и превышений желаемой границы с допуском нет ни одного. Тем не менее 184 из них (18,78%) не выполняют заключительное удержание: тележка остаётся в допустимой области все десять секунд, а задача подъёма и захвата при этом не решена. Приписывать этим 184 эпизодам ту же причину, что установлена в предыдущей главе для отдельных DDPG-траекторий, нельзя — DDPG в robustness-матрицу не входит, и по агрегатам механизм не определяется.

Парные исходы показывают ту же картину с другой стороны. Из 980 пар оба режима успешны 434 раза, только on — 362, только off — 7, ни один — 177. Все семь пар, где успех достигнут только без фильтра, содержат превышение желаемой границы с допуском, поэтому примерами утраты *успеха без превышения* они не являются, хотя утрату исходного успеха отражают. Рисунок 9 показывает обе стороны результата. Видеоприложение 3 иллюстрирует устранение остановки по положению; видеоприложение 4 — успех off с превышением желаемой границы и отсутствие успеха on без превышения. Оба примера выбраны по зафиксированному правилу отбора, а не случайно.

Насколько причинно можно читать это сравнение? Между сторонами каждой пары менялся только слой исполнения: контрольные точки, физика и критерии оставались теми же, а старт совпадал точно. На уровне программного интерфейса, впрочем, различаются ещё две вещи — допуск начального состояния и возможность терминального отказа фильтра. Оба различия в данной серии не сработали: все 140 стартов были допущены в обоих режимах, а отказов фильтра в 1960 эпизодах не было ни одного, поэтому наблюдаемый разрыв исходов ими не объясняется. Разница в самих прекращении, однако, реальна: 534 off-эпизода остановились по позиции, тогда как все on дошли до горизонта. Это часть эффекта исполнения, и сравнивать возврат так, будто все траектории длились одинаково, на этих данных нельзя.




Рисунок 9 – Слева — отдельные метрики по 980 эпизодам каждого режима; справа — взаимоисключающие исходы 980 пар.

Общие доли используют равные веса семи групп и веса контроллеров 3 SAC + 3 TQC + 1 классика — это веса исследовательского дизайна. Сетки и зеркальные пары не образуют независимую случайную выборку из всего пространства, поэтому p-values, доверительные интервалы глобального успеха и перенос на практические частоты стартов здесь не приводятся.

5.6 Насколько часто фильтр меняет запрос

Таблица 7 агрегирует вмешательства по числу принятых решений. Всего в режиме on изменено 115 355 из 980 000 решений, то есть 11,7709%, отказов нет; при off показатель неприменим, поскольку защитного слоя просто нет. Малая доля не означает слабого эффекта: одно раннее торможение меняет все последующие состояния и всю дальнейшую обратную связь. По одному агрегату установить, какой именно момент отвечает за конкретный исход, невозможно.

Таблица 7 – Коррекции запросов в robustness, режим on

Семейство	Изменено / принято	Доля, %	Средняя / max $ \Delta u $, м/с ²
SAC, три seed	4209 / 420000	1,00	2,30 / 7,99
TQC, три seed	57179 / 420000	13,61	4,65 / 8,00
Классика	53967 / 140000	38,55	74,70 / 394,64

Источник: Результаты вычислительных экспериментов автора. Средняя величина коррекции рассчитана только среди вмешательств, с суммированием числителей.

Числа по классике в этой таблице требуют пояснения, иначе они читаются неверно. В отличие от запроса обучаемой политики, исходный запрос классического регулятора может превышать предел ускорения, и величина коррекции включает приведение амплитуды к ± 4 м/с². Значения 74,70 и 394,64 м/с², следовательно, не означают приложения таких ускорений и не измеряют одно лишь дополнительное торможение по x и v ; как прямая мера «худшего качества защиты» в сравнении с SAC и TQC они не годятся.

Отдельно отметим расхождение в документации классического исполнителя. В сохранённой спецификации указан контракт среды обучения SAC, тогда как классический контроллер фактически выполняется через другой интерфейс среды, без этого контракта. Проверка полных журналов подтвердила совпадение физики, интегратора, награды и критерия удержания, поэтому соответствующие физические показатели сопоставимы. Полная тождественность наблюдений и пути формирования запросов при этом не установлена, и расхождение сохранено в документации репозитория как есть, без правки исторических метаданных.

Серия выполнена полностью и показывает две вещи: перенос на новые nominal-старты состоялся, а при структурированных отклонениях у фиксированных политик обнаруживаются конкретные пределы захвата. Веса при этом не изменялись — менялись только начальные условия, поэтому снижение успеха относительно nominal характеризует поведение уже обученных политик, а не качество процедуры обучения. Причины ограниченного обобщения этот эксперимент не устанавливает. Он остаётся диагностикой этапа разработки: если по его результатам изменить метод, независимым финальным тестом нового метода он не станет.

Заключение

В одной симуляционной постановке исследованы классический подъём со стабилизацией и четыре метода обучения с подкреплением. Явно зафиксированы ускорительный вход, рабочие ограничения, интервал управления, награда и физический критерий удержания — без этого сравнение методов теряет смысл, поскольку одинаковое название задачи не гарантирует одинаковой динамики.

Основная серия отвечает на вопрос о достижимости рабочего решения при выбранном бюджете. SAC-on и TQC-on дают 20/20 на validation и для лучших, и для последних весов всех трёх seeds. DQN способен находить успешное решение, но отдельные seeds и последние веса заметно хуже. DDPG-on успешен только на одном исходном seed, а SAC-off с базовыми настройками не достигает успеха ни разу. Эти результаты характеризуют конкретные процедуры на исходной узкой области, причём validation участвовала в выборе моделей и потому итоговым тестом не является.

Однофакторный подбор показывает, насколько ограниченным бывает выигрыш настройки. Warmup5000 строго выигрывает Stage 1 у DDPG-on и SAC-off: средняя доля успеха по трём seeds растёт у DDPG с $1/3$ до $2/3$, а у SAC-off с 0 до $1/3$, то есть число успешных запусков увеличивается с одного до двух и с нуля до одного соответственно. Минимум по seeds при этом остаётся нулевым — ни одна из настроек не делает успешными все три запуска. Обе настройки затем не проходят confirmation на seeds 3–5. У SAC-off не подтверждается и предположение о том, что увеличенный начальный сбор опыта улучшает раннее покрытие верхней области: по предварительно закреплённому требованию нужны были два seed из трёх, улучшение наблюдалось у одного.

Сохранённые DDPG-журналы показывают расхождение награды и успеха на уровне механизма. У последних весов seeds 3 и 5 маятник в заключительные две секунды устойчиво находится вверху: угол, угловая скорость и координата тележки удовлетворяют критерию во всех двадцати эпизодах. Прерывает удержание скорость тележки — она допустима лишь в 1925 из 4020 отсчётов для seed 3 и в 2404 из 4020 для seed 5. У seed 3 это сочетается с ростом среднего возврата, то есть суммарной награды за эпизод, с 273,68 до 706,05 при падении успеха с $4/20$ до $0/20$. Диагностика объясняет, почему визуального положения маятника и скалярной награды недостаточно, но причину деградации самих параметров сети не устанавливает.

Структурированная проверка начальных условий оценивает новые старты без новых обучений. На nominal20 фиксированные SAC/TQC и классика почти полностью воспроизводят решение исходной задачи — 139 успехов из 140 исполнений. На осевых, граничных и совместных отклонениях проявляются различия между политиками, скрытые прежней валидацией. На всей фиксированной матрице фильтр повышает успех с $441/980$ до $796/980$ и устраняет наблюденные превышения $0,24$ м с учётом допуска, но $184/980$ эпизода с фильтром доходят до горизонта, не выполнив заключительного удержания. Измеренный парный эффект относится к 140 выбранным состояниям из K и к закреплённым контроллерам, а не ко всей области K .

Собранные вместе, эти результаты разделяют две пары понятий, которые в задачах управления с ограничениями часто смешивают. Первая пара — *безопасность движения тележки*

и *решение задачи*. В режиме *on* все 980 эпизодов доходят до горизонта и ни один не превышает желаемой границы, однако 184 из них задачу не решают; в обратную сторону, все семь пар, где успех достигнут только без фильтра, содержат превышение этой границы. Ни один из двух показателей не выводится из другого, и измерять их нужно порознь — иначе исправная защита положения будет прочитана как работающее управление.

Вторая пара — *повторяемость обучения* и *чувствительность готовой политики к старту*. Это разные свойства, и проверяются они разными экспериментами. Отрицательный *confirmation* говорит о первом: та же процедура на новых *seeds* даёт другой результат. Структурированная матрица говорит о втором: веса не менялись, менялось только начальное состояние — и SAC seeds 0/1/2 показывают 135, 129 и 128 успехов из 140, а TQC — 127, 93 и 99, хотя на прежней валидации все шесть политик были неразличимы с результатом 20/20. Неоднородность, невидимая на узком наборе отбора, проявляется при расширении стартов; при этом *robustness* проверяет фиксированные веса на других начальных условиях и полным доказательством отсутствия переобучения не является.

Практический итог работы — воспроизводимая картина сильных и слабых сторон конкретных процедур, в которой отрицательные исходы сохранены наравне с положительными и снабжены областью применимости. Неизвестными остаются общая область захвата, распределение качества по будущим *seeds*, устойчивость к неопределённости модели и перенос на оборудование; для каждого из этих вопросов нужны новые данные, а не переинтерпретация имеющихся.

Перспективы работы — независимая оценка зафиксированной процедуры на новых стартах и большем числе обучений, перепланирование классического подъёма под каждое начальное состояние, а также учёт задержек, шумов и ошибок исполнения ускорения. Закрытый набор итоговой оценки не создавался и не использовался. Перенос на оборудование требует отдельной проверки модели и привода.

Список использованных источников

- [1] Haarnoja T., Zhou A., Abbeel P., Levine S. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor // Proceedings of the 35th International Conference on Machine Learning. PMLR. 2018. Vol. 80. P. 1861–1870. URL: <https://proceedings.mlr.press/v80/haarnoja18b.html> (дата обращения: 17.09.2026).
- [2] Haarnoja T., Zhou A., Hartikainen K. et al. Soft Actor-Critic Algorithms and Applications. Препринт arXiv:1812.05905v2. Версия 2, 2019. URL: <https://arxiv.org/abs/1812.05905v2> (дата обращения: 17.09.2026).
- [3] Henderson P., Islam R., Bachman P., Pineau J., Precup D., Meger D. Deep Reinforcement Learning that Matters. Препринт arXiv:1709.06560v3. Версия 3, 2019. URL: <https://arxiv.org/abs/1709.06560v3> (дата обращения: 17.09.2026).
- [4] Kuznetsov A., Shvechikov P., Grishin A., Vetrov D. Controlling Overestimation Bias with Truncated Mixture of Continuous Distributional Quantile Critics // Proceedings of the 37th International Conference on Machine Learning. PMLR. 2020. Vol. 119. P. 5556–5566. URL: <https://proceedings.mlr.press/v119/kuznetsov20a.html> (дата обращения: 17.09.2026).
- [5] Lillicrap T. P., Hunt J. J., Pritzel A., Heess N., Erez T., Tassa Y., Silver D., Wierstra D. Continuous Control with Deep Reinforcement Learning. Препринт arXiv:1509.02971v6. Версия 6, 2019. URL: <https://arxiv.org/abs/1509.02971v6> (дата обращения: 17.09.2026).
- [6] Mnih V., Kavukcuoglu K., Silver D. et al. Human-level Control through Deep Reinforcement Learning // Nature. 2015. Vol. 518. P. 529–533. DOI: [10.1038/nature14236](https://doi.org/10.1038/nature14236).
- [7] Raffin A., Hill A., Gleave A., Kanervisto A., Ernestus M., Dormann N. Stable-Baselines3: Reliable Reinforcement Learning Implementations // Journal of Machine Learning Research. 2021. Vol. 22, no. 268. P. 1–8. URL: <https://jmlr.org/papers/v22/20-1364.html> (дата обращения: 17.09.2026).
- [8] Robotics Laboratory. Cart-pole. Исходный лабораторный репозиторий, ветка linear-stable. URL: <https://github.com/robotics-laboratory/cart-pole>. (дата обращения к странице репозитория: 17.09.2026).
- [9] Stable-Baselines Team. TQC — SB3-Contrib Documentation. Документация версии 2.9.0. URL: <https://sb3-contrib.readthedocs.io/en/v2.9.0/modules/tqc.html> (дата обращения: 17.09.2026).
- [10] Tedrake R. Underactuated Robotics. Chapter 8: Linear Quadratic Regulators. MIT, электронный учебный текст. URL: <https://underactuated.mit.edu/lqr.html> (дата обращения: 17.09.2026).

- [11] Tedrake R. Underactuated Robotics. Chapter 10: Trajectory Optimization. MIT, электронный учебный текст. URL: <https://underactuated.mit.edu/trajopt.html> (дата обращения: 17.09.2026).
- [12] Wabersich K. P., Zeilinger M. N. A Predictive Safety Filter for Learning-Based Control of Constrained Nonlinear Dynamical Systems. Препринт arXiv:1812.05506v4. Версия 4, 2021. URL: <https://arxiv.org/abs/1812.05506v4> (дата обращения: 17.09.2026).
- [13] Yuan Z., Hall A. W., Zhou S., Brunke L., Greeff M., Panerati J., Schoellig A. P. Safe-control-gym: A Unified Benchmark Suite for Safe Learning-Based Control and Reinforcement Learning in Robotics. Препринт arXiv:2109.06325v4. Версия 4, 2022. URL: <https://arxiv.org/abs/2109.06325v4> (дата обращения: 17.09.2026).

Приложение А. Полная матрица валидации основной серии

Таблица 8 содержит результаты внешней оценки сохранённых моделей. Все значения — число успехов из 20; три именованных сценария сюда не входят. Пометка on/off в названии конфигурации относится к режиму обучения, а в заголовках столбцов — к режиму исполнения сохранённых весов. Классика имеет 20/20 в обоих режимах, и деление на best/last к ней не применяется.

Таблица 8 – Best/last и режим исполнения; validation20

Конфигурация	Seed	Best on	Best off	Last on	Last off
SAC-on	0	20	20	20	0
SAC-on	1	20	0	20	0
SAC-on	2	20	20	20	20
TQC-on	0	20	0	20	0
TQC-on	1	20	0	20	0
TQC-on	2	20	20	20	0
DQN-on	0	20	0	11	0
DQN-on	1	14	0	14	0
DQN-on	2	20	0	20	0
DDPG-on	0	20	0	20	0
DDPG-on	1	0	0	0	0
DDPG-on	2	0	0	0	0
SAC-off	0	0	0	0	0
SAC-off	1	0	0	0	0
SAC-off	2	0	0	0	0

Показатель относится к выбранным 20 состояниям и вероятность успеха на всём пространстве не оценивает. Лучшие и последние веса принадлежат одному обучению и независимыми повторениями эксперимента не являются; совпадение показателей не означает совпадения самих весов, которые внешняя оценка не изменяет.

Приложение Б. Ключи выбора настройки

Таблица 9 иллюстрирует применение (13). Для формального сравнения использованы полные числа из материала «Точные ключи выбора настройки»; округление ниже служит только удобству чтения. Все компоненты рассчитываются по валидационным состояниям для лучших моделей в режиме обучения и с учётом всех трёх seed, а именованные сценарии исключены.

Таблица 9 – Ключи Stage 1, округлённые до шести знаков

Вариант	$\min p$	$\text{mean } p$	$\min H_f$	$\text{mean } H_f$	$\text{mean } H_\ell$
DDPG baseline	0	0,333333	0	2,338500	2,338500
DDPG lr1e4	0	0,216667	0	0,924833	0,927167
DDPG warmup5000	0	0,666667	0	4,705000	4,705000
SAC-off baseline	0	0	0	0	0,073667
SAC-off lr1e4	0	0	0	0	0,001333
SAC-off warmup5000	0	0,333333	0	2,011333	2,126167

Строгий выигрыш warmup5000 устанавливается на второй компоненте ключа и от округления длительностей не зависит. Это решение об ограниченной последующей проверке, а не признание настройки надёжной. Критерий confirmation остался прежним: каждый новый best не ниже 16/20, минимум два новых last не ниже 16/20, параметры после отбора неизменны, неудачные seeds публикуются. Данные seeds 3–5 подтверждения не дали ни одной из двух конфигураций.

Приложение В. Состав и воспроизводимость электронных материалов

Электронные материалы дополняют отчёт данными и средствами проверки: главная страница репозитория содержит переходы к коду, результатам, моделям, видеопримерам и инструкции запуска. Соответствие разделов исследования данным приведено в Таблице 10, а точные пути, идентификаторы версий и контрольные суммы вынесены в документацию репозитория.

Таблица 10 – Материалы для проверки результатов исследования

Раздел	Содержание электронного приложения
Основная серия	Показатели лучших и последних моделей, история валидации, сравнение режимов исполнения.
Подбор настроек	Результаты вариантов по каждому seed, точные ключи отбора, проверка гипотезы о раннем исследовании.
Новые запуски	Результаты исходных и новых seed, проверка критерия подтверждения, разложение удержания на физические компоненты.
Начальные условия	Точные 140 стартов, результаты по контроллерам и группам, парные исходы, показатели вмешательств.
Модель и исполнение	Конфигурации динамики и среды, спецификация фильтра, шесть выбранных моделей SAC/TQC, инструкции запуска.

Уровни воспроизводимости различаются, и смешивать их не следует. Компактные таблицы позволяют заново проверить суммы, доли и применение правил выбора без обучения моделей; для пересчёта всех метрик из исходных переходов нужны полные журналы, а для повторного исполнения — среда симуляции и сохранённый контроллер. Большие исходные архивы и буферы опыта в раздаточный комплект не входят, а шесть моделей SAC/TQC предназначены для исполнения и данных для возобновления прежних обучений не содержат. Из четырёх обучаемых методов в комплект вошли только эти два: выбранные веса DDPG и DQN в него не включены.

Исходники отчёта и команды сборки позволяют получить PDF с теми же таблицами и рисунками; основной текст набран Times New Roman, и для самостоятельной сборки этот шрифт должен быть установлен. Лабораторная модель и исходная классическая основа заимствованы с указанием источника, алгоритмы DQN, DDPG, SAC и TQC использованы в библиотечных реализациях, а происхождение заимствований и характер помощи при подготовке материалов раскрыты в документации репозитория. Технические сведения о прежних редакциях и проверках сохранены отдельно, чтобы не затруднять чтение научного текста.

Отдельно о статусе изображений. Фотография на Рисунке 1 показывает реальную установку, иллюстрация на Рисунке 2 поясняет её узлы, а Рисунок 3 задаёт соглашения расчётной модели. Ни одно из них не используется для извлечения измерений и не подтверждает аппаратных испытаний обученных политик.

Приложение Г. Видеопримеры сохранённых траекторий

Шесть роликов представлены на странице «Видео экспериментов» электронного приложения. Они созданы из принятых журналов без нового расчёта динамики и по фиксированному правилу отбора. Таблица 11 отделяет иллюстрацию от статистики серий и для каждого ролика указывает границу вывода.

Таблица 11 – Видеоприложения: содержание и границы выводов

Материал	Сценарий и назначение
1. Исходная задача	Классика, SAC seed 0, TQC seed 0; on, общий nominal_00. Один выбранный успешный старт.
2. DDPG: лучшие и последние веса	Confirmation warmup5000 seed 5, validation_1000, on. Разные веса: 90 и 100 тыс. переходов; пример ограничения по скорости при положении маятника около верха.
3. Предотвращение остановки	SAC seed 0, angle_01: off останавливается на 0,25 м, on завершает горизонт с успехом. Первая подходящая пара в закреплённом порядке.
4. Успех и граница	SAC seed 0, angle_16: off успешен с превышением 0,24 м, on неуспешен без превышения. Один из семи исходов «успех только off».
5. Семь групп стартов	SAC seed 0, on; индекс 00 каждой группы. Все выбранные примеры успешны; долей успеха группы это не является.
6. Семь контроллеров	On, общий joint_00. Три SAC, три TQC и классика; все выбранные примеры успешны. К закрытому итоговому набору этот пример отношения не имеет.

Видеопримеры показывают выбранные сохранённые траектории и статистику серий не заменяют. Для каждого ролика в репозитории указаны исходные эпизоды и правило отбора, сохранены фактические времена движения, а после окончания эпизода его панель останавливается. При расчёте метрик интерполяция изображения между кадрами не используется, и краткое вмешательство фильтра вполне может прийтись на промежуток между кадрами. Поэтому численные выводы работы основаны на журналах, а не на визуальной оценке роликов.

Электронные материалы работы

Код и конфигурации, таблицы и графики, шесть видео, выбранные модели SAC/TQC, протоколы и инструкции воспроизведения доступны в открытом репозитории электронных материалов работы.

<https://github.com/nefedovdima/cartpole-coursework-submission>