

Национальный исследовательский университет
«Высшая школа экономики»

Факультет компьютерных наук
Образовательная программа
«Прикладная математика и информатика»

Управление перевёрнутым маятником методами обучения с подкреплением

Промежуточный отчёт по курсовой работе

Модель, протокол экспериментов и текущие результаты

Автор: Дмитрий Нефедов

Научный руководитель:
Бондарев Андрей Олегович

16 сентября 2026 года

Эксперименты в симуляции. Итоговая проверка на held-out final ещё не проводилась.

1 Аннотация и постановка задачи

Исследуется подъём маятника из нижнего положения (*swing-up*) и его удержание около неустойчивого верхнего равновесия посредством ускорения тележки. Сравниваются классический контроллер, DQN, DDPG, SAC и TQC. Для нейросетевых методов используется общая модель, награда R1 и одинаковый бюджет в 100 000 переходов. Дополнительный safety-фильтр ограничивает движение тележки.

Основной промежуточный результат: SAC-on и TQC-on успешно решают задачу на всех трёх training seeds в пределах текущего validation-протокола. Это не утверждение о робастности во всём пространстве состояний.

1.1 Текущее состояние

Основная серия включает 15 обучений: четыре метода с фильтром и SAC без фильтра, каждый на seeds 0, 1, 2. Сохранены и проверены best и last checkpoints. Классика даёт 23/23 успешных эпизода; SAC-on и TQC-on дают по 23/23 на каждом seed. DQN-on даёт 23/23, 16/23 и 23/23; DDPG-on существенно зависит от seed. SAC-off в основной серии не достигает успеха. Раздельные результаты на 20 validation-стартах и трёх named-сценариях приведены далее [3].

Для DDPG-on и SAC-off завершён Stage1: проверены увеличенный warmup и уменьшенная скорость обучения. Confirmation на новых seeds 3, 4, 5 завершён и независимо проверен. Для обеих конфигураций критерий подтверждения не выполнен: CONFIRMED=False. Отрицательные результаты приведены в разделе 8 и не заменяют собой результаты основной серии [5].

1.2 Установка и цель управления

Тележка движется горизонтально, маятник свободно вращается вокруг шарнира. Нижнее положение соответствует $\theta = 0$, верхнее — $\theta = \pi$ с точностью до полного оборота. Управление должно поднять маятник, погасить угловое движение и обеспечить удержание, одновременно сохраняя допустимые положение и скорость тележки.




Рис. 1. Система и обозначения. Угол отсчитывается от нижней вертикали; u — ускорение тележки. Пунктиром показана желаемая граница $|x| = 0,24$ м. Схема построена по уравнениям и соглашениям проекта [1].

Работа ограничена симуляцией. Аппаратная реализация и идентификация параметров реальной установки в текущий этап не входят.

2 Математическая модель и RL-постановка

Полное физическое состояние обозначается $s = (x, v, \theta, \omega)$, где $v = \dot{x}$ и $\omega = \dot{\theta}$. Внутренний порядок координат Drake — (x, θ, v, ω) ; при анализе он явно преобразуется к физическим обозначениям. Модель имеет вид [1]

$$\dot{x} = v, \quad \dot{v} = u, \quad \dot{\theta} = \omega, \quad \dot{\omega} = -\frac{u \cos \theta + g \sin \theta}{l}. \quad (1)$$

Входом является ускорение, поэтому масса маятника не входит в эти уравнения. Нельзя интерпретировать u как силу или переносить сюда без изменения модели силовой вход стандартной задачи CartPole.

Параметр	Значение	Смысл
Ускорение свободного падения g	9,8 м/с ²	симуляция
Длина маятника l	0,18 м	шарнир-масса
Масса в конфигурации	0,118 кг	не входит в динамику выше
Рабочие пределы ($ x , v , u $)	(0,25; 2; 4)	м; м/с; м/с ²
Предельные настройки backend	(0,27; 2,5; 5)	те же единицы
Удержание команды Δt	0,01 с	постоянное u на шаге
Горизонт эпизода T	10 с	до 1000 переходов
Интегратор	Runge-Kutta 3	адаптивный шаг
Целевая точность / макс. шаг	10^{-6} / 0,01 с	fixed-step выключен

Таблица 1. Параметры из конфигураций и сохранённых журналов. Рабочие события остановки наступают раньше предельных настроек backend.

2.1 Состояние, наблюдение и действия

Физическое пространство состояний четырёхмерно: $x, v, \omega \in \mathbb{R}$, угол периодичен, хотя в журнале хранится без оборачивания. Во время штатного эпизода действуют рабочие ограничения на x и v . Агент получает нормированное наблюдение типа float32:

$$o(s) = \left(\frac{x}{0,25}, \frac{v}{2}, \sin \theta, \cos \theta, \frac{\omega}{\sqrt{9,8/0,18}} \right). \quad (2)$$

Пара $(\sin \theta, \cos \theta)$ устраняет разрыв представления угла при полном обороте. SAC, TQC и DDPG выбирают $a \in [-1, 1]$, которому соответствует запрос $u_{\text{req}} = 4a$. DQN выбирает один из девяти запросов $\{-4, -3, \dots, 3, 4\}$ м/с². После фильтра исполненная команда DQN может находиться между узлами сетки.

2.2 Награда R1 и дисконтирование

Пусть $q(z) = (1+z^2)^{-1}$, $h(\theta) = (1 - \cos \theta)/2$, а d_t — признак терминального отказа. По состоянию в конце фактического перехода вычисляется

$$R_{1,t} = \frac{\Delta t_{\text{actual}}}{0,01} h(\theta) q\left(\frac{x}{0,25}\right) q\left(\frac{v}{2}\right) q\left(\frac{\omega}{2}\right) q\left(\frac{u_{\text{applied}}}{40}\right) - 5d_t. \quad (3)$$

Награда поощряет верхнее положение, малые скорости и центральное положение тележки. Постоянного бонуса за выживание нет. Множитель управления эквивалентен $q(0,1u/4)$; заменять его на $q(u/4)$ нельзя. При нулевой длительности отказа положительная часть равна нулю. Коэффициент $\gamma = e^{-0,01/5} \approx 0,998002$ фиксирован на переход. Для SAC/TQC оптимизация дополнительно включает энтропию запросов; отчётный return содержит только сумму R1.

3 Успех, завершение эпизода и безопасность

3.1 Критерий успешного удержания

Периодическая ошибка верхнего положения равна

$$e_\theta = \text{atan2}(\sin(\theta - \pi), \cos(\theta - \pi)).$$

Успех требует полного горизонта 10 с без failure и непрерывного заключительного интервала не короче 2 с, на котором по всем записанным состояниям одновременно выполнены

$$|e_\theta| \leq 10^\circ, \quad |\omega| \leq 0,5 \text{ рад/с}, \quad |x| \leq 0,20 \text{ м}, \quad |v| \leq 0,20 \text{ м/с}. \quad (4)$$

Раздельные интервалы не складываются. Кратковременный проход через верх, максимальное удержание в середине эпизода и конечное удержание — разные метрики. Проверка удержания проводится по отсчётам с шагом управления; непрерывная гарантия для угла между отсчётами не заявляется.

Исход	Флаг среды	Обучающее значение
Выход за рабочую область	terminated	штраф -5 , без bootstrap
Отказ safety-фильтра	terminated	$\Delta t = 0$, исполненной команды нет
Достижение 10 с без failure	truncated	bootstrap по конечному наблюдению
Техническое исключение	ошибка исполнения	не маскируется обычным переходом

Физические события положения и скорости обрабатываются внутри шага. Касание границы с возвратом допускается, выход из рабочей области приводит к остановке. Успех не завершает эпизод досрочно: проверяется удержание именно в его конце [1].

3.2 Safety-фильтр

Фильтр стоит между запросом контроллера и симулятором. Для положения x , скорости v и времени удержания команды он выбирает допустимое ускорение в пределах $|u| \leq 4$, ограничивая движение тележки и сохраняя тормозной запас. При $A = 4$, $B = 0,24 \cdot 10^{-6}$, $W = 2 \cdot 10^{-6}$ используется внутренняя область

$$\mathcal{K} = \left\{ (x, v) : \begin{array}{l} |x| \leq B, \quad |v| \leq W, \\ x + \frac{\max(v, 0)^2}{2A} \leq B, \quad -x + \frac{\max(-v, 0)^2}{2A} \leq B \end{array} \right\}. \quad (5)$$

Эти неравенства учитывают тормозной путь при движении к каждой границе. Фильтр проверяет допустимость на всём интервале постоянной команды и состояние в его конце; допустимый запрос сохраняется, иначе корректируется. Невозможность безопасного решения приводит к явному отказу. Для максимума положения учитывается внутренний экстремум $x(\tau) = x_0 + v_0\tau + u\tau^2/2$, если $\tau = -v_0/u$ лежит внутри шага.

Режим **on** включает фильтр, **off** оставляет рабочее ограничение команды, но отключает дополнительную safety-коррекцию. Обозначение метода (например, SAC-on) относится к обучению; режим внешней оценки указывается отдельно. В replay сохраняется запрос агента, а исполненная команда служит отдельной диагностикой.

Безопасность тележки и успех задачи оцениваются раздельно. Фильтр не гарантирует подъём маятника. Успех с фильтром относится к системе «политика + фильтр».

Обоснование фильтра предполагает точные x, v , постоянную команду без задержек и возмущений. Запас 10^{-6} м — инженерный резерв, а не универсальная оценка ошибки численного интегрирования.

4 Методы и экспериментальный протокол

4.1 Пять методов

Классический контроллер. Используется заранее сохранённая траектория подъёма, рассчитанная методом прямой коллокации. TVLQR отслеживает её по закону $u = u_0 - K(t)(q - q_0) - k_0(t)$. После окончания плана происходит однократное переключение на LQR около верхнего положения без повторного планирования. Длительность плана 2,256697944 с; при сетке 0,01 с переключение наступает в 2,26 с. Для LQR в порядке (x, θ, v, ω) используются $Q = \text{diag}(10, 1, 10, 1)$, $R = 0,5$ [2].

DQN. Приближает ценность каждого дискретного запроса и выбирает действие с максимальным Q . Используются replay и целевая сеть [6]. В данном проекте сетка содержит девять ускорений; ε -жадное исследование уменьшается от 1 до 0,05 за первые 20% бюджета, целевая сеть обновляется каждые 1000 переходов.

DDPG. Детерминированный actor выбирает непрерывное действие, critic оценивает его ценность [7]. Здесь применяется один critic и независимый гауссов шум со стандартным отклонением 0,1 в нормированных координатах действия. Этот вариант позволяет проверить, достаточно ли детерминированного actor-critic для подъёма при заданном бюджете.

SAC. Стохастический actor обучается с энтропийной регуляризацией, поддерживающей разнообразие запросов [8]. Используются два critic и автоматическая настройка коэффициента энтропии с начальным значением 0,1. Парная серия SAC-off имеет те же настройки и соответствующие начальные параметры сети, но обучение проходит без фильтра.

TQC. Расширяет энтропийный actor-critic распределительными оценками ценности и усечением верхних квантилей [9]. Конфигурация проекта использует два critic по 25 квантилей и параметр отбрасывания 2 на сеть. Назначение метода — уменьшить переоценку ценности; причина нестабильности других методов этим экспериментом не установлена.

4.2 Общие условия и начальные состояния

Нейросети имеют два скрытых слоя по 64 нейрона с ReLU; оптимизатор Adam, learning rate $3 \cdot 10^{-4}$, batch size 64, replay buffer 100 000, одна среда и одно обновление после каждого перехода после warmup 128. Основная серия содержит 99 872 обновления на обучение. Для непрерывных методов $\tau = 0,005$; для DQN используется жёсткое обновление целевой сети. Реализации основаны на Stable-Baselines3 и SB3-Contrib; конкретные версии зафиксированы в конфигурациях [1].

Training seeds 0, 1, 2 задают независимые обучения. Reset использует независимые равномерные компоненты


$$x, v \in [-0,02; 0,02], \quad \theta, \omega \in [-0,05; 0,05]$$

в соответствующих единицах SI. Validation20 — один сохранённый список нижних стартов, полученный с evaluation seeds 1000–1019. Дополнительно оцениваются bottom: (0, 0, 0, 0), plus_002: (0, 0, 0,02, 0) и minus_002: (0, 0, -0,02, 0).

Выбор checkpoint. На 0, 10 000, ..., 100 000 переходов проводится полная детерминированная оценка. Best максимизирует на validation20 лексикографический набор: доля успехов, среднее конечное удержание, среднее максимальное удержание, минус среднее начало подтверждённого удержания, число переходов. При отсутствии такого начала используется 11 с. Named-сценарии и return в ранжирование не входят. Last сохраняется на 100 000 переходов.

5 Динамика обучения основной серии

История всех 15 seeds: только 11 реально измеренных оценок каждого run



★ — выбранный best по прежнему selection_score. Reuse исключён из кривых. Это использованная для выбора validation, не final.

Рис. 2. Готовый график независимого аудита основной серии [3]. Показаны все 15 обучений: три seeds в каждой из пяти групп. Столбцы: успех, конечное удержание и return на validation20; звёздочки — выбранные best. Каждая кривая содержит 11 реально измеренных оценок, без добавления повторно использованных отчётов.

Успех и награда изменяются немонотонно. SAC-on и TQC-on находят полностью успешные checkpoints, однако отдельные промежуточные оценки существенно хуже. У DQN seed0 после успешного best качество снижается. У DDPG основная серия разделяется на один успешный seed и два неуспешных; усреднение по seeds скрыло бы это различие.

Внешняя оценка: для каждого best/last проведены режимы filter off и on на тех же 23 стартах, то есть 92 эпизодных слота на обучение. Для классики — 46. Термин «внешняя» обозначает отдельное исполнение сохранённых checkpoints; это не новый независимый набор состояний. Повторяющиеся политики best/last не считаются независимыми наблюдениями.

6 Основные результаты

Метод / режим обучения	Seed 0	Seed 1	Seed 2
SAC-on, best; оценка on	20 + 3	20 + 3	20 + 3
TQC-on, best; оценка on	20 + 3	20 + 3	20 + 3
DQN-on, best; оценка on	20 + 3	14 + 2	20 + 3
DDPG-on, best; оценка on	20 + 3	0 + 0	0 + 0
SAC-off, best; оценка off	0 + 0	0 + 0	0 + 0
Классика; оценка on	20 + 3; training seed не применяется		
Классика; оценка off	20 + 3; training seed не применяется		

Таблица 2. Успех на validation20 + named3; запись 20 + 3 означает 23/23. Все значения взяты из полной проверенной таблицы основной серии [3].




Рис. 3. Зависимость best-результата от training seed. Только validation20; режим оценки совпадает с обучением. Диаграмма построена из полного evaluation_summary.csv, пересчитанного в аудите по журналам эпизодов.

6.1 Интерпретация

SAC-on и TQC-on. Все три best дают 20/20 на validation и 3/3 на named. Корректный вывод — воспроизводимое решение на трёх seeds в данном протоколе. Вывод о превосходстве на произвольных состояниях или о глобальной устойчивости не следует из этих данных.

DQN-on. Успешные политики найдены, но seed1 решает лишь 14/20 validation-стартов и 2/3 named-сценариев. Best seed0 на 80 000 переходах даёт 23/23, а last — 13/23 (11/20 + 2/3). Продолжение обучения само по себе не гарантирует улучшения.

DDPG-on и SAC-off. DDPG best seed0 даёт 23/23, seeds1/2 — 0/23. У SAC-off все три best и last дают 0/23; включение фильтра только при внешней оценке этих checkpoints результата не меняет. Успех одного seed DDPG недостаточен для заключения об устойчивой обучаемости.

6.2 Безопасность — отдельный результат

Во всех 713 внешних эпизодных слотах основной серии с filter on не зафиксированы превышения $|x| > 0,24$ м, события position limit или отказы фильтра; максимальное положение равно 0,239999 м. Это описательная проверка данного набора траекторий. Классика без фильтра успешна в 23/23, но пересекает желаемую границу 0,24 м в 21/23 случаях, не достигая события 0,25 м. С фильтром сохраняется 23/23 и превышений нет.

7 Зависимость от checkpoint и фильтра

Метод	Seed	Best off	Best on	Last off	Last on
SAC-on	0	20+3	20+3	0+0	20+3
	1	0+0	20+3	0+0	20+3
	2	20+3	20+3	20+3	20+3
TQC-on	0	0+0	20+3	0+0	20+3
	1	0+0	20+3	0+0	20+3
	2	20+3	20+3	0+0	20+3
DDPG-on	0	0+0	20+3	0+0	20+3
	1	0+0	0+0	0+0	0+0
	2	0+0	0+0	0+0	0+0
DQN-on	0	0+0	20+3	0+0	11+2
	1	0+0	14+2	0+0	14+2
	2	0+0	20+3	0+0	20+3
SAC-off	0	0+0	0+0	0+0	0+0
	1	0+0	0+0	0+0	0+0
	2	0+0	0+0	0+0	0+0

Таблица 3. Внешняя оценка best/last с filter off/on, все seeds. В каждой ячейке успехи на validation20 + named3. Источник — полная проверенная таблица основной серии [3]. Техническое принятие TQC seed1 завершено в Stage1 без новых эпизодов [4]; научные числа не изменились.

Best и last. У SAC-on и TQC-on last также даёт 23/23 при оценке on, однако длительность заключительного удержания может снизиться. У DQN seed0 падение 23/23 → 13/23 показывает практическую важность сохранения промежуточных checkpoints. Best выбирается по заранее определённым физическим метрикам, а не по максимальной накопленной награде.

Парное отключение фильтра. У DDPG-on seed0 best меняется с 23/23 при on на 0/23 при off. Аналогично SAC-on seed1, TQC-on seeds0/1 и все три DQN-on best без фильтра дают 0/23. Для этих политик фильтр является необходимой частью успешного исполнения на рассмотренных стартах. У SAC-on seeds0/2 и TQC-on seed2 best фильтр не вмешивается; они успешны и без него.




Рис. 4. Проверенный confirmation seed5 DDPG-on: best 90k и last 100k на validation_1000. На последних 2 с угол остаётся около верхнего положения, но last нарушает $|v| \leq 0,20$ м/с. Подробности серии — в разделе 8.

8 Stage1 и проверенный confirmation

В Stage1 для DDPG-on и SAC-off отдельно изменяли только один параметр: warmup 128 $\rightarrow$ 5000 либо learning rate $3 \cdot 10^{-4} \rightarrow 10^{-4}$. Бюджет, модель, reset, reward, архитектура и правило выбора best сохранены. Выполнено 12 обучений на seeds 0/1/2. Warmup5000 даёт 95 000 обновлений, вариант learning rate — 99 872 [4].

Вариант	DDPG-on, best /20	SAC-off, best /20
Основная серия	20, 0, 0	0, 0, 0
Stage1: learning rate 10^{-4}	0, 13, 0	0, 0, 0
Stage1: warmup5000	0, 20, 20	20, 0, 0

Таблица 4. Раздельные серии; внутри ячейки seeds 0, 1, 2. Оценка в режиме обучения, named не входят.

Оба warmup5000 выбраны по заранее зафиксированному правилу: минимум и среднее успеха по seeds, затем минимум и среднее конечного удержания, затем среднее максимального удержания. Минимальный успех остался нулевым. Победа в development-отборе поэтому ещё не подтверждает повторяемость улучшения.




Рис. 5. Warmup5000: best и last на validation20. Граница отделяет Stage1 seeds0–2 от новых seeds3–5.

Пунктир — 16/20. Обе серии независимо проверены; named3 исключены. Источник — полные таблицы Stage1 и confirmation [4, 5].

Confirmation: warmup5000	Seed 3	Seed 4	Seed 5
DDPG-on: best / last, из 20	4/0	0/0	20/0
SAC-off: best / last, из 20	0/0	0/0	0/0

Заранее заданный критерий требует best не ниже 16/20 у *каждого* нового seed, last не ниже 16/20 хотя бы у двух из трёх и завершенности всех заданий. Независимый аудит подтвердил **CONFIRMED=False для обеих конфигураций**; named3 исключены из gate, final-набор не использовался. У DDPG новые best неоднородны, а все last неуспешны; SAC-off не воспроизводит единичный успех Stage1 seed0.

DDPG confirmation seed5. Best 90k даёт 20/20, last 100k — 0/20. Среднее конечное удержание снижается с 7,8915 до 0,0115 с, хотя средний return R1 остаётся высоким: 752,57 $\rightarrow$ 665,45. На последних 2 с last угол, угловая скорость и положение удовлетворяют порогам во всех 20 эпизодах; удержание нарушает скорость тележки. В 19/20 эпизодах порог скорости нарушен и в конечном состоянии. Это конкретное объяснение провала критерия, а не доказательство причины деградации обучения.

9 Трактория и анимации сохранённых эпизодов




Рис. 6. SAC-on, seed1, best 50 000, filter on, старт (0, 0, 0, 0). Последние 2 с выделены фоном; конечное удержание 7,44 с, 24 вмешательства фильтра на 1000 переходах. Угол показан как периодическая ошибка; её скачок на границе $\pm 180^\circ$ не является скачком физического угла. $\Delta u = u_{\text{applied}} - u_{\text{req}}$.




Рис. 7. Стоп-кадры приложенных видео: сверху классика и SAC, снизу TQC и парное сравнение DDPG best/last. Видеофайлы содержат время, состояние, команду и вмешательства фильтра.

Все анимации реконструированы из полных журналов: показан каждый четвёртый сохранённый отсчёт, 25 кадров/с, без нового исполнения политик или интегрирования динамики. Геометрия использует $l = 0,18$ м. Для каждой записи проверены контрольная сумма и критерий удержания.

- **Классика, MP4:** фиксированный контроллер, filter on, bottom; успех, hold 7,82 с.
- **SAC-on, MP4:** seed1, best 50k, bottom; успех, hold 7,44 с.
- **TQC-on, MP4:** seed0, best 80k, bottom; успех, hold 6,80 с.
- **DDPG-on, MP4:** confirmation warmup5000, seed5, validation_1000; best 90k (hold 7,90 с) и last 100k (hold 0 с). Видео содержит график скорости с порогами $\pm 0,20$ м/с.

bottom означает $(x, v, \theta, \omega) = (0, 0, 0, 0)$. Для DDPG старт $\approx (0,000855; 0,004154; -0,002906; -0,029675)$ в SI; точные значения сохранены в манифесте. Относительные ссылки работают при сохранении относительной структуры docs/report и media; их открытие зависит от настроек PDF-просмотрщика.

10 Ограничения и план следующего этапа

10.1 Что пока нельзя заключить

1. **Область стартов узкая.** Training и validation сосредоточены около нижнего положения. Нет оснований распространять полученные доли успеха на большие смещения, скорости или произвольные углы.
2. **Validation использовался для выбора best.** Повторная внешняя оценка на тех же состояниях подтверждает сохранённый результат, но не даёт независимой оценки обобщения. Одни и те же 20 состояний повторяются между seeds; это не 60 независимых стартов.
3. **Три seeds — ограниченное свидетельство.** Нельзя выводить общую вероятность успешного обучения или надёжный рейтинг методов из одной удачной реализации. Неудачные seeds сохранены в результатах.
4. **Безопасность условна.** Фильтр проверен на представленных траекториях при идеализированных предположениях; шум, задержки, неопределённость модели и реальная установка не исследованы. Порог безопасности тележки не подменяет критерий удержания.
5. **Причина деградации не установлена.** Наблюдаемые изменения reward, удержания и отдельных диагностик обучения не доказывают переоценку Q , недостаток exploration или архитектуры. Полные высокоточные training-траектории не сохранены; полные evaluation-логи доступны.
6. **Held-out final ещё не использовался.** Confirmation по новым training seeds проверяет повторяемость конфигурации на текущем validation, а не перенос на новые области состояний. Независимый аудит confirmation завершён; обе конфигурации не прошли критерий подтверждения.

10.2 Structured robustness: сначала оценка существующих политик

На 16.09.2026 протокол и шесть main-best checkpoints SAC-on/TQC-on зафиксированы: 140 development-стартов в семи группах, 98 заданий и 1960 эпизодов с классикой и парными режимами фильтра. Отдельно предусмотрен замер на 40 эпизодах. **Робастность ещё не измерена**; при подготовке submission rollout не выполнялись. Точные диапазоны и допуски: [подготовленный протокол](#).

Категория	Предмет проверки
Nominal	новые development-старты в исходной нижней области
Position stress	начальные смещения x при контроле прочих координат
Velocity stress	уровни и знаки v , направление к границе и тормозной запас
Angle stress	начальные углы вне узкой окрестности нижнего положения
Angular-velocity stress	уровни ω и их согласование с углом
Boundary recovery	восстановление из допустимых состояний у границы
Joint robustness	совместные изменения координат по заданным стратам

Для каждой категории зафиксированы допустимость стартов, общие состояния, режимы фильтра и отдельные метрики успеха и безопасности. Все старты допустимы для фильтра; это ограничивает сравнение off/on внутренним множеством и не доказывает успешный подъём. Неудачи нельзя исключать из объявленного знаменателя. Заведомо недопустимые для фильтра старты относятся к отдельной проверке отказов.

После **оценки существующих политик** решить, нужны ли curriculum или переобучение с randomized reset. Если переобучение потребуется, провести отдельный development-отбор, затем отдельный confirmation на новых seeds. После окончательной фиксации методов, настроек и критериев — **однократный held-out final**, без последующей настройки по его результатам.

11 Источники и воспроизводимость

Экспериментальные числа взяты из сохранённых полных таблиц независимых аудитов основной серии, Stage1 и confirmation. Новые диаграммы результата по seeds и Stage1/confirmation построены по этим таблицам, а график траектории — по полному журналу эпизода. Готовый график learning curves включён без изменения данных; матрица best/last переоформлена в читаемую таблицу. Исходные графики проекта также приложены в каталоге figures. Исходная схема проекта сохранена отдельно; схема в тексте адаптирована к актуальным обозначениям модели.

В submission сохранены исходники, конфигурации, компактные таблицы, четыре готовых видео и контрольные суммы их источников. Полные журналы, модели и архивы восстановления хранятся отдельно. При первоначальной подготовке видео по пяти журналам проверены R1 и конечное удержание. Полный повтор аудита моделей и всей серии при подготовке отчёта не выполнялся. Хеши, длинные пути и служебные детали вынесены из основного текста в сопроводительные материалы.

Список литературы

- [1] Нефедов Д. *Общий экспериментальный контракт и Gymnasium: RL_ENV_SPEC; конфигурации обучения и исходный код модели, среды и R1*. Материалы проекта, версия на 16.09.2026. Локальные копии: [контракт](#), [физика](#), [R1](#).
- [2] Нефедов Д. *TrackingThenBalance и зафиксированный классический контроллер*. Материалы проекта. [Исходный код](#); [номинальная траектория](#).
- [3] *Аудит основной серии: S10/S11. Полные таблицы внешних оценок*. 15.09.2026. Материалы проекта: [сводка результатов](#), [таблицы](#), [полный CSV](#). Позднейшее закрытие технического принятия TQC seed1 отражено в [4].
- [4] *Независимый аудит Development Stage1*. 16.09.2026. Материалы проекта: [сводка](#), [полная таблица](#).
- [5] *Development confirmation: протокол, таблицы assess и документ независимого аудита*. 16.09.2026. [Протокол](#); [таблицы](#); [сводка результатов](#). [Формальный gate](#): обе конфигурации не подтверждены; независимый аудит завершён.
- [6] Mnih V., Kavukcuoglu K., Silver D. et al. *Playing Atari with Deep Reinforcement Learning*. 2013. [arXiv:1312.5602](#).
- [7] Lillicrap T. P., Hunt J. J., Pritzel A. et al. *Continuous Control with Deep Reinforcement Learning*. 2015. [arXiv:1509.02971](#).
- [8] Haarnoja T., Zhou A., Abbeel P., Levine S. *Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor*. ICML, PMLR 80, 2018. P. 1861–1870. [Статья](#).
- [9] Kuznetsov A., Shvechikov P., Grishin A., Vetrov D. *Controlling Overestimation Bias with Truncated Mixture of Continuous Distributional Quantile Critics*. ICML, PMLR 119, 2020. P. 5556–5566. [Статья](#).

Внешние публикации использованы только для краткого описания методов; их экспериментальные результаты не подменяют результаты данной курсовой. Ссылки проверены при подготовке отчёта.

Описание применения генеративной модели: OpenAI Codex использовался для помощи с кодом, тестами, анализом, текстом и оформлением отчёта. Численные результаты происходят из сохранённых экспериментов. Характер помощи, ограничения и требования раскрытия: [отдельная декларация](#). Она не заменяет форму ВШЭ при сдаче.